Correção - AV1 Machine Learning

Aluno: Gabriel de Souza Vieira

IMPA Tech, 2025.2

1. (1pt) Sobre o método dos Mínimos Quadrados Ordinários (MQO) ou OLS *sigla em inglês*

   (a) Qual é a fórmula para o estimador $\hat{\beta}_{OLS}$ em termos da matriz design X, quando essa tem posto máximo?
   A fórmula do estimador $\hat{\beta}_{OLS}$ é dada por:

   $$\boxed{\hat{\beta}_{OLS} = (X^T X)^{-1} X^T y}$$

   Em que X é a matriz design e y é o vetor de observações.

   (b) Deduza esta fórmula.
   Vamos deduzir a fórmula. O método dos mínimos quadrados consiste em minimizar a soma dos resíduos (RSS), que é dada por:

   $$RSS = \sum_{i=1}^{n} (y_i - \hat{y_i})^2$$

   Que podemos escrever na forma matricial:

   $$RSS = (y - X\beta)^2$$

   Expandindo temos:

   $$\begin{aligned} RSS &= (y - X\beta)^T (y - X\beta) \\ &= (y^T - \beta^T X^T)(y - X\beta) \\ &= y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X\beta \end{aligned}$$

   Vemos que o segundo termo é um escalar, e qualquer escalar é igual ao seu transposto, com isso temos que $(y^T X\beta) = (y^T X\beta)^T = \beta^T X^T y$. Assim:

   $$RSS = y^T y - 2\beta^T X^T y + \beta^T X^T X\beta$$

   Como queremos minimizar o RSS, derivamos em relação a β e igualamos a 0, vamos derivar termo a termo de RSS:

Primeiro termo $y^T y$:
Como esse termo não depende de β, a sua derivada é igual a 0.

Segundo termo $-2\beta^T X^T y$:
Esse termo pode ser visto como um produto interno de β^T com $X^T y$, em que a derivada é dada por

$$\frac{\partial(\beta^T X^T y)}{\partial \beta} = X^T y$$

Terceiro termo $\beta^T X^T X \beta$:
Na expressão temos uma matriz simétrica entre os vetores β^T e β, então a sua derivada é dada por

$$\frac{\partial(\beta^T X^T X \beta)}{\partial \beta} = 2X^T X \beta$$

Assim:

$$\frac{\partial RSS}{\partial \beta} = -2X^T y + 2X^T X \beta = 0$$

Manipulando:

$$-2X^T y + 2X^T X \beta = 0$$
$$X^T X \beta = X^T y$$
$$\boxed{\hat{\beta}_{OLS} = (X^T X)^{-1} X^T y}$$

Mas a derivada igual a zero indica um ponto crítico, em que pode ser de máximo ou mínimo, então para avaliar esse ponto precisamos calcular a Hessiana:

$$\frac{\partial^2 RSS}{\partial \beta \partial \beta^T} = 2X^T X$$

E temos que $X^T X$ é positiva definida:

$$v^T (X^T X) v = (Xv)^T (Xv) = ||Xv||^2 > 0$$

Uma função convexa tem um mínimo global se a sua Hessiana é positiva semidefinida, e temos que $2X^T X$ é positiva definida, então garantimos que o ponto crítico é de mínimo global.

(c) Mostre que trata-se de um estimador não viciado com variância $(X^T X)^{-1}\sigma^2$, onde σ^2 é a variância do ruído.
Primeiro verificando que é um estimador não viciado. Um estimador é não viciado se $\mathbb{E}[\hat{\beta}] = \beta$.

Substituindo $y = X\beta + \varepsilon$ no $\hat{\beta}_{OLS}$:

$$\begin{aligned}\hat{\beta}_{\text{OLS}} &= (X^T X)^{-1} X^T (X\beta + \varepsilon) \\ &= (X^T X)^{-1} X^T X\beta + (X^T X)^{-1} X^T \varepsilon \\ &= \beta + (X^T X)^{-1} X^T \varepsilon\end{aligned}$$

Tomando a esperança e usando as propriedades de linearidade e esperança de uma constante:

$$\begin{aligned}\mathbb{E}[\hat{\beta}_{OLS}] &= \mathbb{E}[\beta + (X^T X)^{-1} X^T \varepsilon] \\ &= \mathbb{E}[\beta] + \mathbb{E}[(X^T X)^{-1} X^T \varepsilon] \\ &= \beta + (X^T X)^{-1} X^T \mathbb{E}[\varepsilon]\end{aligned}$$

Supomos que o erro médio é 0 ($\mathbb{E}[\varepsilon] = 0$), logo $\boxed{\mathbb{E}[\hat{\beta}_{OLS}] = \beta}$, então temos que é um estimador não viciado.

Agora calculando a variância, que é dada por:

$$\begin{aligned}Var(\hat{\beta}_{OLS}) &= \mathbb{E}\left[\left(\hat{\beta}_{OLS} - \mathbb{E}[\hat{\beta}_{OLS}]\right)^2\right] \\ &= \mathbb{E}\left[\left(\hat{\beta}_{OLS} - \beta\right)\left(\hat{\beta}_{OLS} - \beta\right)^T\right] \\ &= \mathbb{E}\left[((X^T X)^{-1} X^T \varepsilon)((X^T X)^{-1} X^T \varepsilon)^T\right] \\ &= \mathbb{E}\left[(X^T X)^{-1} X^T \varepsilon\varepsilon^T X (X^T X)^{-1}\right] \\ &= (X^T X)^{-1} X^T \mathbb{E}\left[\varepsilon\varepsilon^T\right] X (X^T X)^{-1}\end{aligned}$$

Sabemos que ε é um vetor de erros aleatórios, quando fazemos $\varepsilon\varepsilon^T$ criamos uma matriz em que os elementos da diagonal são ε_i^2 e os elementos fora da diagonal são $\varepsilon_i\varepsilon_j$. Quando tiramos a esperança de uma matriz, calculamos a esperança entrada a entrada, para os elementos da diagonal temos $\mathbb{E}[\varepsilon_i^2] = \sigma^2$ e para os elementos fora da diagonal temos $\mathbb{E}[\varepsilon_i\varepsilon_j] = 0$ pois os erros são independentes entre si, então temos que essa matriz é a identidade multiplicada por σ^2. Assim:

$$\begin{aligned}Var(\hat{\beta}_{OLS}) &= (X^T X)^{-1} X^T \mathbb{E}\left[\varepsilon\varepsilon^T\right] X (X^T X)^{-1} \\ &= (X^T X)^{-1} X^T \sigma^2 I X (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1} X^T X (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1}\end{aligned}$$

Logo temos que a variância é dada por $\boxed{Var(\hat{\beta}_{OLS}) = \sigma^2 (X^T X)^{-1}}$

(d) No caso em que σ^2 não é conhecida, como estimamos a variância de $\hat{\beta}_{\text{OLS}}$?
Quando σ^2 não é conhecido, estimamos usando:

$$\boxed{\hat{\sigma}^2 = \frac{RSS}{n-p}}$$

Sendo n o número de observações e p o número de coeficientes do modelo.

2. (2pts) Considere o modelo de regressão linear

$$y = X\beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$$

Mostre que o estimador de Mínimos Quadrados Ordinários (MQO) é também o estimador de Máxima Verossimilhança (MLE) para β nesse modelo.

Como $y = X\beta + \varepsilon$ e $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$, então:

$$y \sim \mathcal{N}(X\beta, \sigma^2 I)$$

Para cada observação y_i, a sua densidade é dada por:

$$f(y_i|X_i, \beta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y_i - X_i\beta)^2\right)$$

Escrevemos a função de verossimilhança como o produtório das funções densidade

$$\begin{aligned} L(\beta, \sigma^2) &= \prod_{i=1}^{n} f(y_i|X_i, \beta, \sigma^2) \\ &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y_i - X_i\beta)^2\right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - X_i\beta)^2\right) \end{aligned}$$

Podemos escrever a função de verossimilhança na forma matricial:

$$L(\beta, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}(y - X\beta)^T(y - X\beta)\right)$$

Agora tiramos o log da verossimilhança:

$$\ell(\beta, \sigma^2) = \log L(\beta, \sigma^2) = -\frac{n}{2}\log\left(2\pi\sigma^2\right) - \frac{1}{2\sigma^2}(y - X\beta)^T(y - X\beta)$$

Para encontrar o MLE de β, maximizamos $\ell(\beta, \sigma^2)$ em relação a β. O primeiro termo não depende de β, então precisamos maximizar o segundo termo. Quando estamos maximizando um valor negativo, é o mesmo que minimizar o seu valor positivo, Então queremos minimizar $(Y - X\beta)^T(Y - X\beta)$, mas isso é exatamente o MQO, que minimiza a soma dos quadrados dos resíduos. Logo o estimador de Mínimos Quadrados é o mesmo que o estimador de máxima verossimilhança para β.

3. (1pt) Sobre classificadores:

   (a) Defina o classificador de Bayes.

   (b) Defina o risco de um classificador como $Risk(\hat{y}) = P(\hat{y}(X) \neq Y)$. Mostre que o classificador de Bayes minimiza o risco.

4. (1pt) Sobre LDA e QDA

   (a) Explique a diferença entre LDA e QDA em termos de suposições.

   (b) Deduza a expressão para os discriminantes δ_j no LDA e QDA e conclua que a fronteira de decisão entre duas classes é sempre linear no LDA, mas podendo ser quadrática no QDA.

5. (1pt) Sobre métodos de regularização

   (a) Prove que o Ridge produz um estimador enviesado.

   (b) Discuta como o Ridge/Lasso podem produzir modelos com MSE das previsões menor que o modelo dado pelo MQO.

6. (2pts) O uso de regressão linear na investigação de algoritmos.
   Considere um algoritmo de busca em grafos, como a busca em largura (BFS), que explora um grafo aleatório com n vértices. Após executar o algoritmo, seja Z_n o número de vértices visitados após n passos. Suponha que você suspeita que o valor esperado de Z_n cresce assinoticamente como uma potência de n, ou seja, $E[Z_n] \sim Cn^{\alpha}$ para algum expoente $\alpha \in (0, 1)$ e constante positiva C, ambos desconhecidos.

   Mostre como podemos utilizar simulações do algoritmo e regressão linear usando o método dos mínimos quadrados para construir um estimador $\hat{\alpha}$ não-viciado para α. Qual a interpretação do intercepto nessa regressão?

7. (2pts) Considere o fragmento de código abaixo:

```
1  from sklearn.linear.model import LinearRegression, Ridge, Lasso
2  from sklearn.preprocessing import StandardScaler
3  from sklearn.model_selection import cross_validate, KFold
4  import numpy as np
5
6  ...
7
8  scaler = StandardScaler()
9  X_scaled = scaler.fit_transform(X)
10
11 kf = KFold(n_splits=5, shuffle=True, random_state=1)
12
13 ols = LinearRegression()
14 ridge = Ridge(alpha=1.0)
15 lasso = Lasso(alpha=0.1)
16
17 ols_results = cross_validate(ols, X_scaled, y, cv=kf)
18 ridge_results = cross_validate(ridge, X_scaled, y, cv=kf)
19 lasso_results = cross_validate(lasso, X_scaled, y, cv=kf)
20
21 print(f"OLS: {np.mean(ols_results['test_score'])}")
22 print(f"Ridge: {np.mean(ridge_results['test_score'])}")
23 print(f"Lasso: {np.mean(lasso_results['test_score'])}")
```

Responda:

(a) Qual propósito geral do script acima?

(b) Qual o papel da linha 9? Por que ela é um passo importante?

(c) Qual o papel do `cross_validate` nas linhas 17-19 e como ele auxilia na escolha do modelo com melhor capacidade de generalização?

(d) Discuta como a escolha dos valores de `alpha` pode influenciar os resultados dos modelos Ridge e Lasso.