Estudo dirigido I

AUTOR Rodrigo Ribeiro CURSO Aprendizado de Máquina I (MD22) INSTITUIÇÃO IMPA Tech PERÍODO 2026.2

Olá pessoas, como prometido, aqui está o estudo dirigido! Ele percorre, na ordem das notas de aula, os capítulos *O que significa aprender?*, *Visão geral de Aprendizado de Máquina supervisionado* e *Regressão Linear*. Cada seção abre com a leitura recomendada e uma lista do que você deve saber, seguida de exercícios de quatro tipos:

> **Conceitual**: relacionar conceitos e entender o que cada definição mede e para que serve.
>
> **Prático**: cálculo à mão ou experimentação com os widgets.
>
> **Demonstração**: provar.
>
> **Programação**: implementar; código correto basta, sem preocupação com eficiência; Python puro, NumPy permitido, sem `scikit-learn`.

Alguns exercícios (ou itens) estão marcados como **Desafio**: exigem mais de um passo ou um resultado que não está nas notas. Não são obrigatórios, mas quem fizer vai entender o resto com muito mais folga.

1 O que significa aprender?

Leitura: capítulo *O que significa aprender?*.

Você deve saber

> Enunciar o laço *dados* → *método* → *medida de performance* e dizer o que cada componente codifica.
>
> Explicar por que aprender exige os três, e o que falha quando um falta.
>
> Reconhecer os três componentes em um problema descrito em palavras.

EXERCÍCIO 1.1 (TRÊS PROBLEMAS)

EXERCÍCIO 1.1 (TRÊS PROBLEMAS)

Para cada cenário, responda: é regressão ou classificação? O interesse é previsão ou inferência? Quais são N e p? O que são os *dados*, o que seria um *método* e qual *medida de performance* você usaria?

a. O IGAM quer entender ***quais*** parâmetros medidos em campo (pH, turbidez, condutividade, OD, temperatura) explicam a concentração de arsênio nas suas cerca de 660 estações.

b. Um banco quer decidir se novos clientes vão ou não pagar um empréstimo, a partir de 10 mil empréstimos passados descritos por 8 variáveis.

c. Um fundo quer prever a variação percentual semanal do Ibovespa a partir das variações semanais de três índices estrangeiros, usando 5 anos de dados.

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 1.2 (A MEDIDA É UMA DECISÃO)

Considere um filtro de spam.

a. Descreva dois filtros A e B e duas medidas de performance m_1 e m_2 tais que m_1 prefere A e m_2 prefere B.

b. O que a escolha entre m_1 e m_2 diz sobre o problema, e não sobre os filtros?

c. Por que "porcentagem de acertos nos e-mails usados para construir o filtro" não é uma medida de ***aprendizado***? O que ela mede, então?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 1.3 (SISTEMA DE RECOMENDAÇÃO COM MEDIDA)

EXERCÍCIO 1.3 (SISTEMA DE RECOMENDAÇÃO COM MEDIDA)

Retome o recomendador de filmes do capítulo.

a. Gere um catálogo fictício (título, gênero, diretor) e um conjunto de usuários, cada um com uma lista de filmes assistidos e uma nota.
b. Implemente o recomendador aleatório e o ponderado (que conta gêneros e diretores preferidos).
c. Defina uma medida de performance, por exemplo a fração de recomendações cujo gênero coincide com o gênero mais bem avaliado por um usuário ***que não foi usado*** para ajustar os pesos. Compare os dois recomendadores.

TIPO Programação USO DE IA Permitido

2 Aprendizado de máquina supervisionado

2.1 Do problema concreto ao problema matemático

Leitura: capítulo *Visão geral de AM supervisionado*, seções *Um problema concreto*, *Um problema matemático* e *O problema concreto e o problema matemático*.

Você deve saber

Identificar preditores e resposta; distinguir regressão de classificação.

Enunciar o modelo $Y = f(X) + \varepsilon$ e dizer o que f e ε representam.

Explicar por que interpolar os dados não é aprender f (fenômeno de Runge).

EXERCÍCIO 2.1 (O MODELO $Y = f(X) + \varepsilon$)

EXERCÍCIO 2.1 (O MODELO $Y = f(X) + \varepsilon$)

a. No problema do arsênio, o que a função f representa? Ela existe mesmo que ninguém a conheça?

b. Mostre que exigir $\mathbb{E}[\varepsilon] = 0$ é uma ***convenção***, não uma hipótese: se $\mathbb{E}[\varepsilon] = c \neq 0$, redefina f e ε para que valha.

c. Há duas fontes de ε: variáveis relevantes que não foram medidas e o erro de medição do laboratório. Qual delas diminui coletando ***mais amostras***? E coletando ***mais variáveis***? Qual delas nenhum método consegue reduzir?

d. Suponha que $\mathrm{Var}(\varepsilon)$ dependa de x (rios limpos têm medições mais precisas). O que muda na previsão de f? E na avaliação do erro de uma estimativa $\hat{f}$?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.2 (INTERPOLAR NÃO É APRENDER)

O polinômio interpolador de grau $N - 1$ passa por todos os N pontos: seu risco empírico é zero.

a. Por que isso não faz dele uma boa estimativa de f? O que ele "aprende" além de f?

b. Usando o fenômeno de Runge, explique por que aumentar N pode ***piorar*** o interpolador, quando um bom método deveria melhorar com mais dados.

c. Que hipótese sobre f e sobre ε tornaria interpolar razoável?

d. Reamostrar apenas o ruído ε (mantendo os x_i) muda muito o interpolador. Que nome esse fenômeno vai receber mais adiante?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.3 (EXISTÊNCIA E UNICIDADE DO INTERPOLADOR)

Sejam $x_1, \ldots, x_N$ distintos. Mostre que a matriz de Vandermonde $V_{ij} = x_i^{j-1}$ é invertível, e conclua que existe um único polinômio de grau no máximo $N - 1$ passando por (x_i, y_i), $i = 1, \ldots, N$. O que acontece se dois x_i coincidem? 💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 2.4 (INTERPOLAÇÃO DE LAGRANGE E SUA INSTABILIDADE)

EXERCÍCIO 2.4 (INTERPOLAÇÃO DE LAGRANGE E SUA INSTABILIDADE)

a. Implemente `lagrange(xs, ys)`, que devolve uma função `p(x)` avaliando o polinômio interpolador $\sum_i y_i L_i(x)$.

b. Fixe $x_1, \dots, x_{10}$ igualmente espaçados em $[-1, 1]$ e $f(x) = \sin(3x)$. Gere $y_i = f(x_i) + \varepsilon_i$ com $\varepsilon_i \sim \mathcal{N}(0, 0{,}1^2)$, interpole e avalie em $x_0 = 0{,}95$.

c. Repita (b) 100 vezes, reamostrando apenas o ruído. Reporte a média e o desvio padrão de $p(x_0)$ e compare com $f(x_0)$.

TIPO Programação USO DE IA Permitido

2.2 Por que e como estimar f

Leitura: seções *Por que estimar f?* e *Como estimar f?* (minimização do risco empírico, máxima verossimilhança, modelos paramétricos e não-paramétricos, não há almoço grátis).

Você deve saber

Distinguir previsão de inferência e dizer o que cada uma exige de $\hat{f}$.

Definir função perda, risco empírico e o estimador ERM; explicar o papel da classe $\mathcal{G}$.

Mostrar que máxima verossimilhança com ruído gaussiano é ERM com perda quadrática.

Distinguir paramétrico de não-paramétrico, e parâmetro de hiperparâmetro.

Comparar as perdas ℓ_1 e ℓ_2.

EXERCÍCIO 2.5 (O QUE O RISCO EMPÍRICO MEDE?)

EXERCÍCIO 2.5 (O QUE O RISCO EMPÍRICO MEDE?)

a. Em palavras, o que $\frac{1}{N}\sum_{i=1}^{N}\ell(y_i,\hat{y}_i)$ mede? Por que é uma ***média***? Que resultado de probabilidade justifica usá-la?

b. O ERM tem dois ingredientes, a perda ℓ e a classe $\mathcal{G}$. Qual deles codifica ***o que nos importa*** e qual codifica ***o que acreditamos sobre*** f?

c. O que o ERM devolve se $\mathcal{G}$ é o conjunto de todas as funções? E se $\mathcal{G}$ é o conjunto das funções constantes?

d. Conclua: o risco empírico mede a qualidade do ***ajuste***. Que quantidade mediria ***aprendizado***?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.6 (PREVISÃO OU INFERÊNCIA?)

Para o arsênio (em mg/L), o modelo $\hat{f}_A(x) = 15{,}2 \cdot \text{pH} - 2{,}1 \cdot \text{turbidez} - 5$ tem erro de teste maior que um kNN com $k = 7$, $\hat{f}_B$.

a. Qual dos dois você entrega ao laboratório que quer parar de medir arsênio? Por quê?

b. Qual você entrega ao órgão ambiental que pergunta "reduzir a turbidez ajuda?"

c. Interprete o coeficiente $15{,}2$, com unidades. O sinal de $-2{,}1$ significa que turbidez ***causa*** menos arsênio?

d. Por que não há nada análogo a interpretar em $\hat{f}_B$?

e. Descreva um cenário em que o modelo com ***maior*** erro de teste é a escolha certa.

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.7 (PARAMÉTRICO VERSUS NÃO PARAMÉTRICO)

EXERCÍCIO 2.7 (PARAMÉTRICO VERSUS NÃO-PARAMÉTRICO)

a. Liste vantagens e desvantagens de um método paramétrico frente a um não-paramétrico. Em que situação (tamanho de N, conhecimento sobre f) você prefere cada um?

b. "O kNN não tem parâmetros." Corrija a frase. Qual a diferença entre parâmetro e hiperparâmetro?

c. Por que k não pode ser escolhido minimizando o risco empírico nos dados de treino? Que k sairia?

d. Em que sentido a "quantidade de informação" que o kNN guarda cresce com N, enquanto a da regressão linear não?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.8 (ESCOLHENDO A PERDA)

Algumas estações têm concentrações de arsênio dezenas de vezes maiores que as demais.

a. Sabendo que, entre as funções constantes, ℓ_2 escolhe a média e ℓ_1 a mediana (Exercício 2.11), qual perda você usaria para prever uma estação "típica"? E para não subestimar as estações críticas?

b. O que se perde ao trocar ℓ_2 por ℓ_1 do ponto de vista de ***como*** encontrar o minimizador?

c. Proponha uma perda que penalize mais ***subestimar*** o arsênio do que superestimá-lo. Que efeito ela tem sobre a $\hat{f}$ obtida por ERM?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.9 (REGRESSÃO SEM INTERCEPTO À MÃO)

EXERCÍCIO 2.9 (REGRESSÃO SEM INTERCEPTO A MÃO)

Considere $Y = \beta X + \varepsilon$ e os dados abaixo.

TABELA 2.1

X	Y
1	3
2	4
3	8
4	10

a. Encontre $\hat{\beta}$ que minimiza o risco empírico com perda quadrática.

b. Mostre que $\hat{\beta}x$ é a projeção ortogonal do vetor $y \in \mathbb{R}^4$ sobre a reta gerada por $x \in \mathbb{R}^4$. O que o vetor $y - \hat{\beta}x$ tem de especial?

TIPO Prático USO DE IA Não recomendado

EXERCÍCIO 2.10 (VEROSSIMILHANÇA É RISCO EMPÍRICO)

a. Se $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, mostre que maximizar a verossimilhança condicional de $y_1, \ldots, y_N$ dado $x_1, \ldots, x_N$ é minimizar o risco empírico com perda quadrática.

b. Se ε tem densidade de Laplace $\frac{1}{2b}e^{-|t|/b}$, que perda aparece?

c. Conclua: o que a escolha da perda revela sobre a nossa crença a respeito do ruído?

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 2.11 (MÉDIA E MEDIANA COMO ERM)

EXERCÍCIO 2.11 (MÉDIA E MEDIANA COMO ERM)

Seja $\mathcal{G}$ o conjunto das funções constantes $g(x) = c$. Mostre que o ERM com $\ell_2(y, \hat{y}) = (y - \hat{y})^2$ devolve $c = \bar{y}$, e que com $\ell_1(y, \hat{y}) = |y - \hat{y}|$ devolve uma mediana de $y_1, \ldots, y_N$. Por que isso explica a robustez de ℓ_1 a valores extremos?

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 2.12 (A FUNÇÃO DE REGRESSÃO MINIMIZA O RISCO)

Seja (X, Y) um par aleatório com $\mathbb{E}[Y^2] < \infty$ e defina $f(x) = \mathbb{E}[Y \mid X = x]$.

a. Para qualquer função g, mostre que

$$\mathbb{E}\left[(Y - g(X))^2\right] = \mathbb{E}\left[(Y - f(X))^2\right] + \mathbb{E}\left[(f(X) - g(X))^2\right].$$

Conclua que f minimiza o risco com perda quadrática sobre ***todas*** as funções, e que o valor mínimo é $\mathbb{E}[\mathrm{Var}(Y \mid X)]$, o erro irredutível.

b. Compare com o Exercício 2.11: qual dos dois é a versão ***populacional*** e qual é a ***empírica***? Por que o ERM precisa restringir $\mathcal{G}$, se o minimizador sobre todas as funções é conhecido?

c. **(Desafio)** Mostre que, com a perda ℓ_1, o minimizador é a mediana condicional de Y dado $X = x$.

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 2.13 (ERM EM UMA CLASSE FINITA)

a. Implemente `erm(X, y, G, loss)`, que recebe uma lista de funções `G` e uma perda `loss(y, y_hat)` e devolve a função de menor risco empírico.

b. Use-a com $\mathcal{G} = \{g_\beta(x) = \beta x : \beta \in \{0{,}0, 0{,}1, 0{,}2, \ldots, 5\}\}$ e os dados do Exercício 2.9, com ℓ_2 e com ℓ_1. Compare com o $\hat{\beta}$ calculado à mão.

TIPO Programação USO DE IA Permitido

EXERCÍCIO 2.14 (KNN DE REGRESSÃO)

EXERCÍCIO 2.14 (KNN DE REGRESSÃO)

Implemente, sem bibliotecas além de `math` e `random`, `knn_reg(X, y, x0, k)`, que devolve a média dos y_i dos k pontos mais próximos de `x0`. Gere $N = 100$ pontos de $y = \sin(2\pi x) + \varepsilon$ em $[0, 1]$ e avalie $\hat{f}$ em uma grade fina para $k \in \{1, 5, 20\}$. Descreva o que muda.

TIPO Programação USO DE IA Permitido

2.3 Quão precisa é a estimativa?

Leitura: seção *Quão precisa é a estimativa de f?* (partição dos dados, LOOCV, k-fold, vazamento de dados, a natureza dos erros, trade-off viés-variância, sobreajuste e regularização).

Você deve saber

Definir MSE de treino e de teste e dizer o que cada um mede.

Decompor o risco em erro redutível e irredutível, e o redutível em viés² e variância.

Explicar a curva em U do erro de teste e situar qualquer método nela.

Descrever partição simples, LOOCV e k-fold, com custos e variâncias.

Reconhecer vazamento de dados e explicar o que a regularização faz.

EXERCÍCIO 2.15 (O QUE O MSE MEDE?)

EXERCÍCIO 2.15 (O QUE O MSE MEDE?)

a. No problema do arsênio, em que unidade está o MSE? Por que se costuma reportar a raiz quadrada (RMSE)?

b. $\text{MSE}_{\text{treino}}$ e $\text{MSE}_{\text{teste}}$ medem coisas diferentes. Nomeie cada uma e explique por que a primeira é sistematicamente otimista.

c. Um modelo tem $\text{MSE}_{\text{teste}} = 10^{-4}$. É bom? Responda comparando com o limite legal de 0,01 mg/L e com $\text{Var}(\varepsilon)$.

d. Por que nenhum método consegue, em média, MSE de teste abaixo de $\text{Var}(\varepsilon)$?

e. O que $\text{MSE}_{\text{treino}} \to 0$ indica sobre o método? E sobre o quanto ele aprendeu?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.16 (AS CINCO CURVAS)

Esboce, em um mesmo gráfico com a flexibilidade de $\mathcal{G}$ no eixo horizontal, as curvas de viés², variância, erro de treino, erro de teste e erro irredutível. Explique a forma de cada curva e por que $\text{erro de teste} = \text{viés}^2 + \text{variância} + \text{irredutível}$. Marque onde ficam o interpolador do Exercício 2.2, a função constante e a regressão linear.

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.17 (FLEXÍVEL OU RÍGIDO?)

Para cada situação, diga se espera que uma classe $\mathcal{G}$ flexível ou rígida tenha menor erro de teste, justificando com viés e variância.

a. N enorme e p pequeno.

b. p enorme e N pequeno.

c. f altamente não-linear.

d. $\text{Var}(\varepsilon)$ enorme.

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.18 (DIAGNÓSTICO POR VIÉS E VARIÂNCIA)

EXERCÍCIO 2.18 (DIAGNÓSTICO POR VIÉS E VARIÂNCIA)

Dois métodos foram ajustados aos mesmos dados. Método A: $\text{MSE}_{\text{treino}} = 0{,}1$, $\text{MSE}_{\text{teste}} = 2{,}0$. Método B: $\text{MSE}_{\text{treino}} = 0{,}9$, $\text{MSE}_{\text{teste}} = 1{,}1$.

a. Qual sofre de sobreajuste e qual de subajuste? O que você pode dizer sobre $\text{Var}(\varepsilon)$?

b. Para cada método, diga o que fazer (coletar mais dados, aumentar a flexibilidade, regularizar) e preveja o efeito nos dois erros.

c. Se N dobrar, o que acontece com o viés, a variância, o erro irredutível e a flexibilidade ótima?

d. Se você acrescentar um preditor puramente aleatório, o que acontece com o viés e com a variância?

e. No kNN, quando k cresce, o que acontece com viés e variância? Qual k é o "interpolador"? Qual é a "função constante"?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.19 (VALIDAÇÃO CRUZADA)

a. Descreva como o k-fold é implementado e quantos ajustes ele exige.

b. Vantagens e desvantagens do k-fold em relação a uma única partição treino/teste.

c. Vantagens e desvantagens do k-fold em relação ao LOOCV. Por que o LOOCV pode ter ***maior*** variância, apesar de usar quase todos os dados em cada ajuste?

d. O erro de validação cruzada estima o erro de qual modelo: o ajustado com N pontos ou com $N(1 - 1/k)$? Isso enviesa a estimativa para cima ou para baixo?

💡 Dica

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.20 (VAZAMENTO DE DADOS)

EXERCÍCIO 2.20 (VAZAMENTO DE DADOS)

O conjunto de teste deve simular dados ***futuros***. Para cada procedimento, diga se há vazamento, por quê, e qual seria o sintoma.

a. Padronizar cada coluna usando a média e o desvio padrão de ***todos*** os dados, e só depois separar treino e teste.

b. Escolher o k do kNN pelo erro no conjunto de teste e reportar esse erro como performance.

c. Medições trimestrais da mesma estação aparecem tanto no treino quanto no teste.

d. Preencher valores ausentes de uma coluna pela média da coluna inteira antes de separar.

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.21 (O QUE A REGULARIZAÇÃO FAZ)

Considere o lasso, $\hat{\beta}_\lambda \in \arg\min_\beta \sum_i (y_i - \beta_0 - \beta_1 x_i - \cdots - \beta_d x_i^d)^2 + \lambda \sum_{j=1}^{d} |\beta_j|$, com λ crescendo a partir de zero.

a. Para cada quantidade, diga se ela aumenta sempre, diminui sempre, tem forma de U ou fica constante, e justifique: erro de treino, erro de teste, variância, viés², erro irredutível.

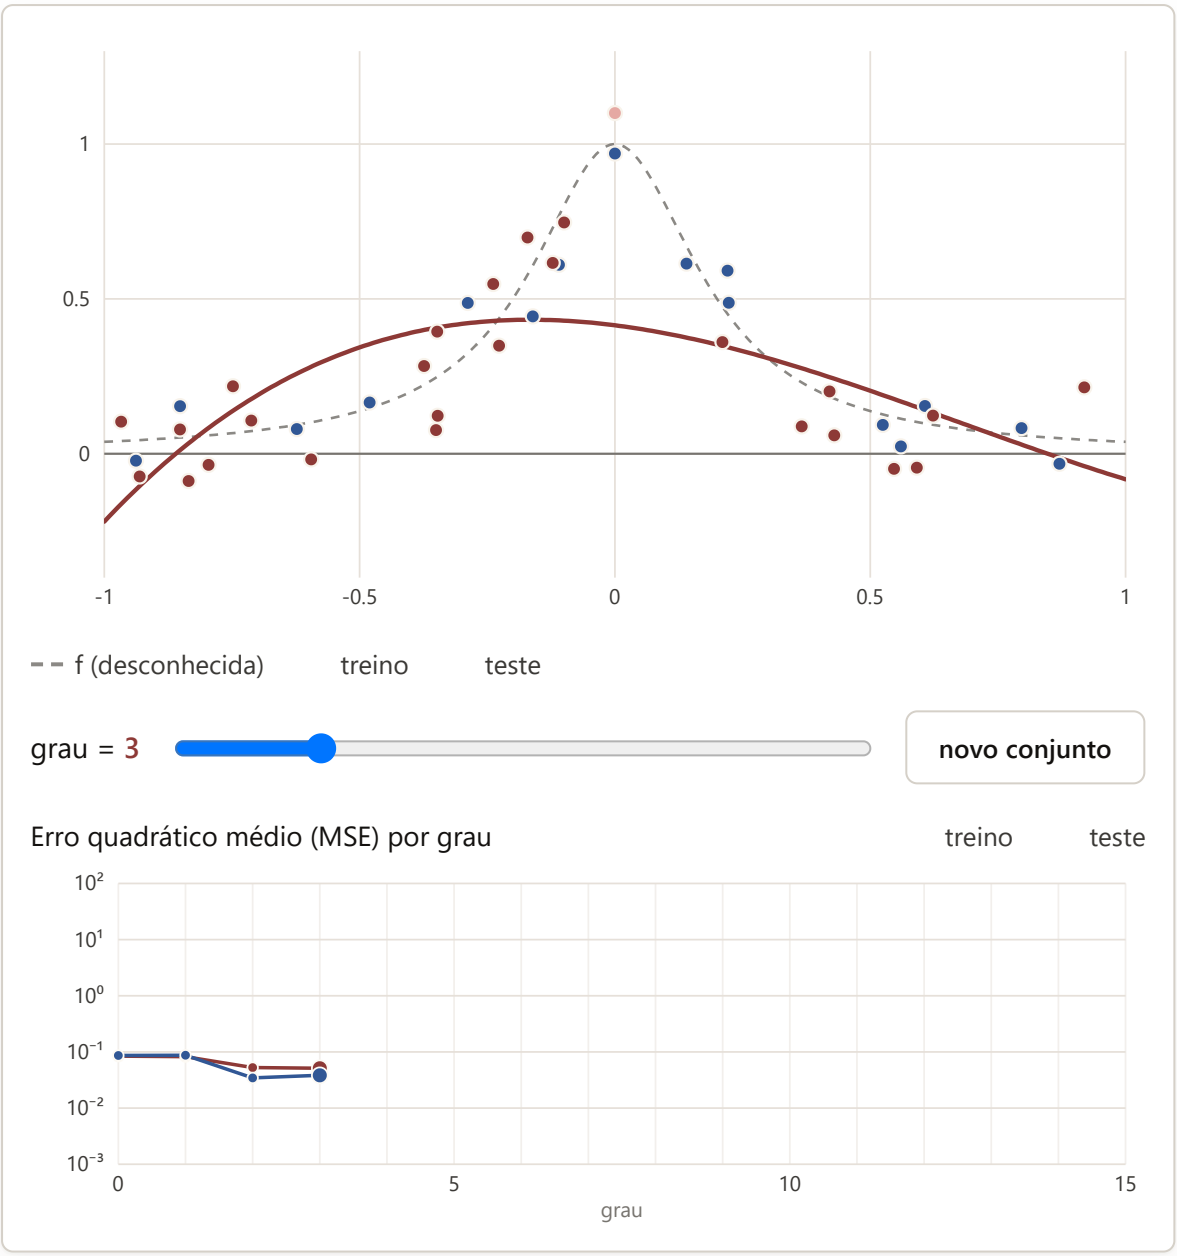
b. Por que β_0 não é penalizado?

c. Se a coluna x for medida em outra unidade (por exemplo, gramas em vez de quilos), a solução muda? O que isso sugere fazer antes de regularizar?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.22 (CORREÇÃO AO VIVO)

EXERCÍCIO 2.22 (SOBREAJUSTE AO VIVO)



INTERATIVO 2.1 Ajuste polinomial de grau variável. Os pontos de treino e de teste vêm da mesma f com o mesmo ruído.

Varie o grau do polinômio e registre, em uma tabela, o MSE de treino e de teste para cada grau. Localize o mínimo do erro de teste e explique, em termos de viés e variância, o que acontece à esquerda e à direita dele. Reamostre o ruído com o grau fixo: qual dos dois erros muda mais? Por quê?

TIPO Prático USO DE IA Não recomendado

EXERCÍCIO 2.23 (ERRO REDUTÍVEL E IRREDUTÍVEL)

EXERCÍCIO 2.23 (ERRO REDUTÍVEL E IRREDUTÍVEL)

Fixe x e seja $Y(x) = f(x) + \varepsilon$. Mostre que

$$\mathbb{E}\left[(Y(x) - \hat{f}(x))^2\right] = \mathbb{E}\left[(f(x) - \hat{f}(x))^2\right] + \mathrm{Var}(\varepsilon),$$

indicando exatamente onde se usa $\mathbb{E}[\varepsilon] = 0$ e onde se usa a independência entre ε e $\hat{f}(x)$. Por que $\hat{f}(x)$ é uma variável aleatória?

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 2.24 (VIÉS E VARIÂNCIA)

Mostre que

$$\mathbb{E}\left[(f(x) - \hat{f}(x))^2\right] = \left(f(x) - \mathbb{E}[\hat{f}(x)]\right)^2 + \mathrm{Var}(\hat{f}(x)).$$

Em relação a que distribuição são tomadas essas esperanças? 💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 2.25 (K-FOLD GENÉRICO)

a. Reescreva `particao_dados` do capítulo para matrizes NumPy, devolvendo índices de treino e teste.

b. Implemente `k_fold(X, y, k, fit, predict, loss)`, em que `fit(X, y)` devolve um modelo, `predict(modelo, X)` devolve previsões e `loss` é a perda. A função devolve o erro médio de validação cruzada.

c. Use-a para escolher o k do kNN do Exercício 2.14 em dados sintéticos. Compare com o k que minimiza o erro de treino.

TIPO Programação USO DE IA Permitido

EXERCÍCIO 2.26 (SIMULANDO VIÉS E VARIÂNCIA)

EXERCÍCIO 2.26 (SIMULANDO VIÉS E VARIÂNCIA)

Fixe $f(x) = \sin(2\pi x)$, $x_0 = 0{,}3$ e $\mathrm{Var}(\varepsilon) = 0{,}1$. Repita 200 vezes: amostre um conjunto de treino com $N = 50$, ajuste o kNN e calcule $\hat{f}(x_0)$. Com as 200 previsões, estime $\left(f(x_0) - \mathbb{E}[\hat{f}(x_0)]\right)^2$ e $\mathrm{Var}(\hat{f}(x_0))$. Repita para $k \in \{1, 3, 10, 30, 50\}$ e confira suas respostas ao Exercício 2.18(e).

TIPO Programação USO DE IA Permitido

2.4 Classificação

Leitura: seção *Problemas de Classificação* (perda 0-1, classificador de Bayes, K vizinhos mais próximos).

Você deve saber

Definir a perda 0-1 e a taxa de erro; construir perdas assimétricas.

Definir o classificador de Bayes e explicar por que ele é ótimo e por que não é utilizável.

Explicar por que o kNN aproxima o classificador de Bayes, e o que K controla.

EXERCÍCIO 2.27 (O QUE A PERDA 0-1 MEDE?)

EXERCÍCIO 2.27 (O QUE A PERDA 0-1 MEDE?)

a. Por que $y - \hat{y}$ não faz sentido quando $y \in \{\text{contaminada}, \text{não-contaminada}\}$? O que a perda $1\{y \neq \hat{y}\}$ mede em seu lugar?

b. Apenas 3% das estações são contaminadas. Qual a taxa de erro do classificador constante "não-contaminada"? Ele é bom?

c. Escreva uma perda assimétrica do capítulo (errar uma estação contaminada custa 2, errar uma limpa custa 1) como uma matriz 2×2 e calcule o risco empírico do classificador constante sob ela.

d. Que perda tornaria um classificador com taxa de erro 20% preferível ao constante? O que isso diz sobre "taxa de erro" como medida de performance?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.28 (O CLASSIFICADOR DE BAYES COMO BARREIRA)

a. Defina o classificador de Bayes.

b. Mostre que ele minimiza o risco de classificação equivocada definida como:

$$R(\widehat{Y}) = \mathbb{P}(Y \neq \widehat{Y})$$

c. Por que ele não pode ser usado na prática? O que um método de aprendizado tenta fazer em relação a ele?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.29 (KNN À MÃO)

EXERCÍCIO 2.29 (KNN À MÃO)

Seis estações foram descritas por três preditores padronizados e rotuladas.

TABELA 2.2

OBS.	X_1	X_2	X_3	Y
1	0	3	0	Limpa
2	2	0	0	Limpa
3	0	1	3	Limpa
4	0	1	2	Contaminada
5	-1	0	1	Contaminada
6	1	1	1	Limpa

Queremos classificar uma nova estação com $X_1 = X_2 = X_3 = 0$.

a. Calcule a distância euclidiana de cada observação ao ponto de teste.

b. Qual a previsão com $K = 1$? E com $K = 3$?

c. Se a fronteira de Bayes for muito não-linear, o melhor K tende a ser grande ou pequeno? Por quê?

d. Com a perda assimétrica do Exercício 2.27, a decisão com $K = 3$ muda? E se errar uma estação contaminada custasse 3?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 2.30 (KNN EM REGRESSÃO E EM CLASSIFICAÇÃO)

a. O que o kNN de regressão e o kNN classificador têm em comum e o que muda? Que quantidade populacional cada um aproxima: $\mathbb{E}[Y \mid X = x]$ ou $\arg\max_j P(Y = j \mid X = x)$?

b. Suponha N pontos uniformes em $[0, 1]^p$ e um ponto de teste no interior. Para prever, selecionamos apenas os pontos dentro de um hipercubo centrado no ponto de teste que se estende 10% do intervalo em ***cada*** coordenada. Que fração dos dados fica dentro deste hipercubo para $p = 1$? $p = 2$? $p = 100$?

c. O que isso implica para o kNN com muitos preditores? Em termos de viés e variância, o que acontece com os "vizinhos" quando p cresce?

d. Para $p = 100$, qual deve ser o lado de um hipercubo centrado no ponto de teste para conter 10% dos dados? Comente.

TIPO Conceitual USO DE IA Não recomendado

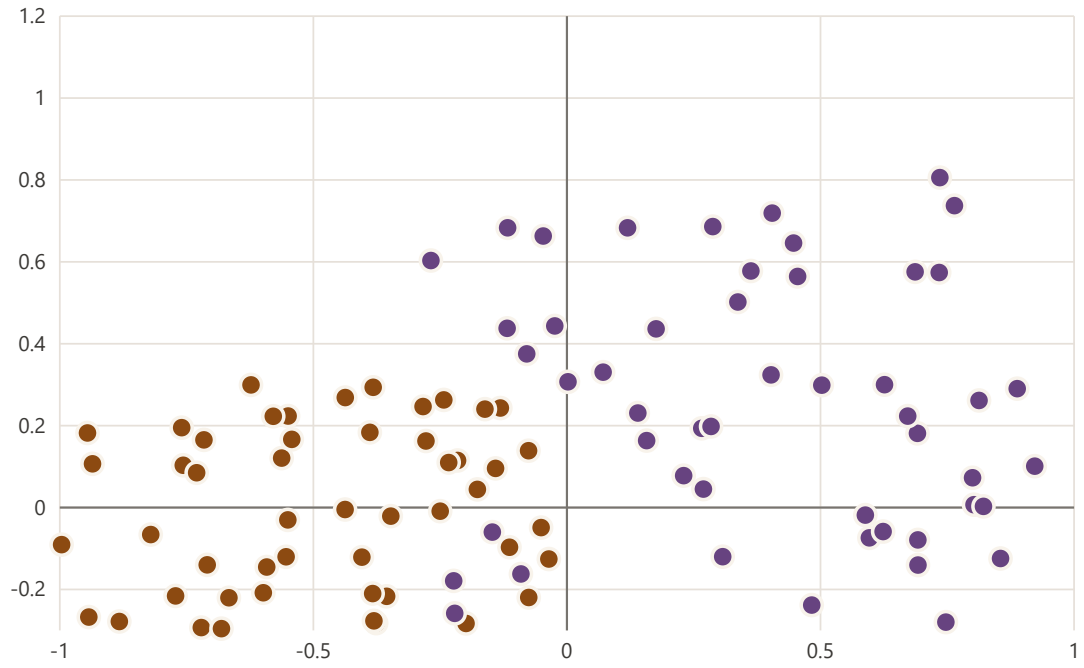
EXERCÍCIO 2.31 (BAYES COM RESPOSTA BINOMIAL)

Seja $Y \mid X = x \sim \text{bin}(4, x)$, com $x \in [0, 1]$. Calcule $\hat{Y}_{\text{Bayes}}(x)$ e o erro de Bayes $P(Y \neq \hat{Y}_{\text{Bayes}}(x) \mid X = x)$ para $x \in \{0{,}1;\ 0{,}5;\ 0{,}9\}$.

TIPO Prático USO DE IA Não recomendado

EXERCÍCIO 2.32 (FRONTEIRAS DO KNN)

EXERCÍCIO 2.32 (FRONTEIRAS DO KNN)



k = 3 Classificar pontos classificar ao adicionar

classificar ao arrastar

Clique no plano para adicionar um ponto · arraste para mover · duplo-clique remove.

INTERATIVO 2.2 Classificador kNN. Clique para acrescentar pontos e use o controle para variar K.

Com os pontos já presentes (acrescente mais, se quiser, com alguma sobreposição), observe as fronteiras para $K = 1$, $K = 3$ e $K = 15$. Descreva o que muda e traduza em viés e variância. Acrescente um ponto isolado no meio da outra classe e repita: para qual K ele mais altera a fronteira?

TIPO Prático USO DE IA Não recomendado

EXERCÍCIO 2.33 (KNN VERSUS BAYES)

EXERCÍCIO 2.33 (KNN VERSUS BAYES)

Tome $X \sim U[0,1]^2$ e $\eta(x) = P(Y = 1 \mid X = x) = \sigma(10\,(x_1 - x_2))$, com $\sigma(t) = 1/(1+e^{-t})$.

a. Implemente `knn_class(X, y, x0, k)` com distância parametrizável e desempate pelo menor rótulo, e `bayes(x0)` usando η.

b. Gere dados dessa lei e compare, em um conjunto de teste grande, a taxa de erro do kNN (com k escolhido por validação cruzada) com a do classificador de Bayes, para $N \in \{50, 200, 1000, 5000\}$. Para onde a diferença converge?

TIPO Programação USO DE IA Permitido

3 Regressão linear

3.1 Mínimos quadrados, caso $p = 1$

Leitura: capítulo *Regressão Linear*, seções *Estimando os coeficientes* e *Caso $p = 1$*.

Você deve saber

Definir RSS e relacioná-la ao MSE.

Deduzir as equações normais para $p = 1$ e resolvê-las.

Justificar que o ponto crítico é mínimo global (convexidade, Hessiana).

Escrever $\hat{\beta}_1 = \mathrm{Cov}(x, y)/\mathrm{Var}(x)$ e interpretar.

EXERCÍCIO 3.1 (O QUE RSS E $\hat{R}^2$ MEDEM?)

EXERCÍCIO 3.1 (O QUE RSS E β MEDEM?)

a. RSS e MSE diferem por um fator N. Qual das duas serve para comparar ajustes em conjuntos de tamanhos diferentes? Qual aparece naturalmente na verossimilhança?

b. Por que mínimos quadrados soma distâncias ***verticais*** e não perpendiculares à reta? Relacione com o que é aleatório no modelo $Y = \beta_0 + \beta_1 X + \varepsilon$.

c. Em $\hat{\beta}_1 = \mathrm{Cov}(x, y)/\mathrm{Var}(x)$, quais as unidades de $\hat{\beta}_1$? Se $\hat{\beta}_1 = 0$, Y é independente de X? Dê um contraexemplo.

d. O vetor de resíduos $r = y - \hat{y}$ é ortogonal ao vetor de uns e ao vetor x. Traduza cada ortogonalidade em uma frase sobre o ajuste.

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.2 (LINEAR OU CÚBICO?)

Suponha que a relação verdadeira seja $Y = \beta_0 + \beta_1 X + \varepsilon$ e que ajustemos, aos mesmos dados, uma reta e um polinômio cúbico.

a. Qual dos dois tem menor RSS de treino, ou não é possível dizer? Justifique.

b. E RSS de teste?

c. Repita (a) e (b) supondo que a relação verdadeira é não-linear, mas não sabemos o quanto.

Relacione as respostas com o Exercício 2.17.

TIPO Conceitual USO DE IA Não recomendado

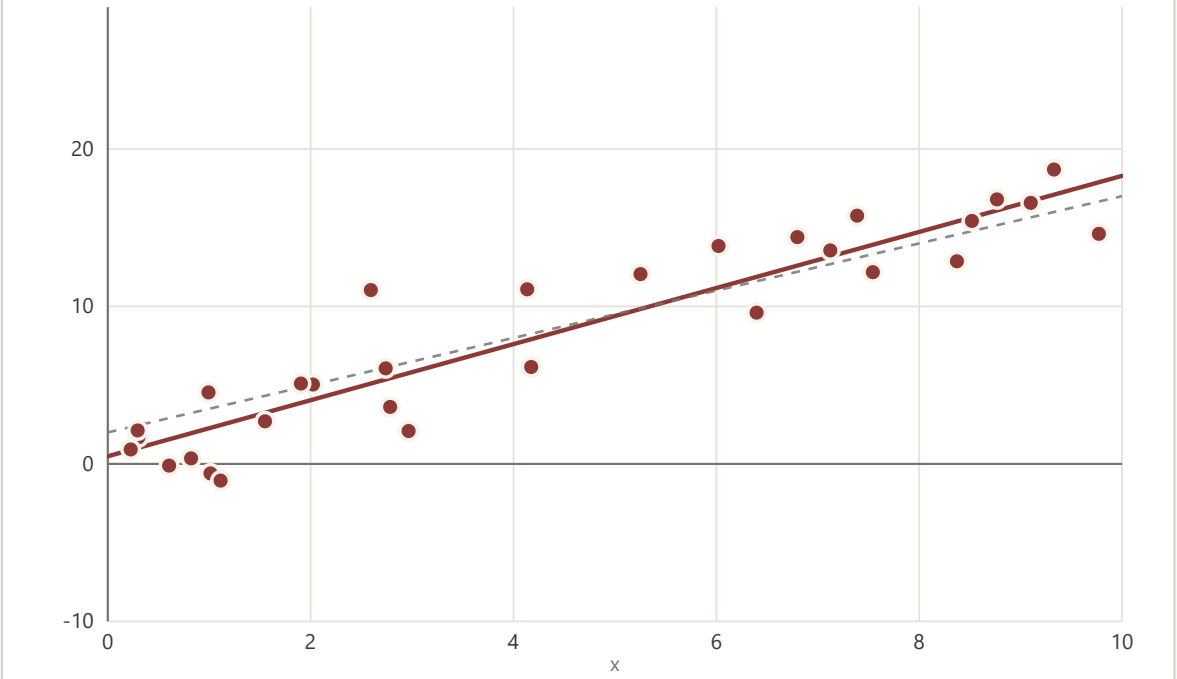
EXERCÍCIO 3.3 (COM INTERCEPTO, À MÃO)

Para os dados do Exercício 2.9, ajuste $Y = \beta_0 + \beta_1 X + \varepsilon$: calcule $\hat{\beta}_0$, $\hat{\beta}_1$ e a RSS. Compare com a RSS do ajuste sem intercepto. Por que a RSS não pode ter aumentado?

TIPO Prático USO DE IA Não recomendado

EXERCÍCIO 3.4 (A LA VANGUARDA)

EXERCÍCIO 3.4 (ALAVANCAGEM)



reta verdadeira (desconhecida) amostra mínimos quadrados

$\hat{\beta}_0 = 0.48 \cdot \hat{\beta}_1 = 1.78$ RSS = 150.04 · MSE = 5 $\beta_0 = 2 \cdot \beta_1 = 1.5$

N = 30 Var(ε) = 4 resíduos

rastro IC da reta predição nova amostra

Clique no plano para adicionar um ponto · arraste para mover · duplo-clique remove.

INTERATIVO 3.1 Regressão linear simples. A reta tracejada é a verdadeira; a cheia, o ajuste. Clique para acrescentar um ponto e arraste-o.

a. Reamostre várias vezes com $N = 10$ e depois com $N = 120$. O que acontece com a dispersão de $\hat{\beta}_1$? Qual termo da decomposição viés-variância isso ilustra?

b. Acrescente um ponto no centro da nuvem e arraste-o verticalmente; depois faça o mesmo com um ponto na borda. Qual altera mais a reta? Explique com os pesos $(x_i - \bar{x})$ na fórmula de $\hat{\beta}_1$.

TIPO Prático USO DE IA Não recomendado

EXERCÍCIO 3.5 (EQUAÇÕES NORMAIS PARA $p = 1$)

EXERCÍCIO 3.5 (EQUAÇÕES NORMAIS PARA $p = 1$)

a. Derive as equações normais para $\mathrm{RSS}(\beta_0, \beta_1)$ e resolva-as, obtendo $\hat{\beta}_1$ e $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$.

b. Conclua que a reta ajustada passa por $(\bar{x}, \bar{y})$ e que os resíduos satisfazem $\sum_i r_i = 0$ e $\sum_i x_i r_i = 0$.

c. No ajuste sem intercepto, mostre que $\hat{y}_i = \sum_{i'} a_{i'} y_{i'}$ e encontre os $a_{i'}$. Em que sentido "a previsão é uma combinação linear dos y"? Que $y_{i'}$ pesam mais?

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.6 (O PONTO CRÍTICO É MÍNIMO)

Mostre que a Hessiana de $\mathrm{RSS}(\beta_0, \beta_1)$ é definida positiva se, e somente se, existem i, j com $x_i \neq x_j$. O que acontece com $\hat{\beta}$ quando todos os x_i são iguais? Interprete geometricamente. 💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.7 (MÉDIA E VARIÂNCIA DE $\hat{B}_1$)

Suponha $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ com os x_i fixos e os ε_i independentes, de média zero e variância σ^2.

a. Mostre que $\hat{\beta}_1 = \sum_i w_i y_i$ com $w_i = (x_i - \bar{x}) / \sum_j (x_j - \bar{x})^2$. Onde se usa $\sum_i w_i = 0$?

b. Mostre que $\mathbb{E}[\hat{\beta}_1] = \beta_1$ e $\mathrm{Var}(\hat{\beta}_1) = \sigma^2 / \sum_i (x_i - \bar{x})^2$.

c. Interprete: o que acontece com a variância quando N cresce? E quando os x_i ficam mais espalhados? Relacione com o que você observou no Exercício 3.4.

d. Mostre que $\mathbb{E}[\hat{\beta}_0] = \beta_0$ e $\mathrm{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{N} + \frac{\bar{x}^2}{\sum_i (x_i - \bar{x})^2} \right)$. Por que centrar os x_i torna $\hat{\beta}_0$ mais preciso?

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.8 (PITÁGORAS E R^2)

EXERCÍCIO 3.8 (PITÁGORAS E R^2)

Defina $\mathrm{TSS} = \sum_i (y_i - \bar{y})^2$, $\mathrm{RSS} = \sum_i (y_i - \hat{y}_i)^2$ e $R^2 = 1 - \mathrm{RSS}/\mathrm{TSS}$.

a. Usando as identidades do Exercício 3.5(b), mostre que $\mathrm{TSS} = \sum_i (\hat{y}_i - \bar{y})^2 + \mathrm{RSS}$. Interprete como o teorema de Pitágoras em $\mathbb{R}^N$: quais são os três vetores do triângulo?

b. Conclua que $0 \leq R^2 \leq 1$ e mostre que, para $p = 1$, $R^2 = \mathrm{Cor}(x, y)^2$. O que $R^2 = 0$ diz sobre a reta ajustada?

c. Padronize x e y (média 0, variância 1). Mostre que $\hat{\beta}_0 = 0$ e $\hat{\beta}_1 = \mathrm{Cor}(x, y)$. A regressão de x sobre y é a inversa da regressão de y sobre x? Explique por que isso justifica o nome ***regressão*** (à média).

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.9 (IMPLEMENTANDO $P = 1$)

Implemente `ols_p1(x, y)` devolvendo $(\hat{\beta}_0, \hat{\beta}_1)$ pelas fórmulas fechadas. Em dados sintéticos, verifique numericamente as três identidades do Exercício 3.5(b).

TIPO Programação USO DE IA Permitido

3.2 Caso geral

Leitura: seção *Caso geral*.

Você deve saber

Montar a matriz design e escrever $\mathrm{RSS}(\beta) = (y - X\beta)^T (y - X\beta)$.

Deduzir $\hat{\beta} = (X^T X)^{-1} X^T y$ e dizer quando $X^T X$ é invertível.

Mostrar que a Hessiana $2X^T X$ é semidefinida positiva.

Interpretar $\hat{y} = X\hat{\beta}$ como a projeção ortogonal de y sobre o espaço das colunas de X.

EXERCÍCIO 3.10 (IDENTIFICABILIDADE)

EXERCÍCIO 3.10 (IDENTIFICABILIDADE)

a. Mostre que X^TX é invertível se, e somente se, as colunas de X são linearmente independentes.

b. Traduza a condição em termos dos preditores.

c. Dê um exemplo com $p = 2$ em que uma coluna é múltipla da outra. Quantas soluções o problema de mínimos quadrados tem? O ajuste $\hat{y} = X\hat{\beta}$ é único?

d. Explique por que (c) é um problema para inferência, mas não necessariamente para previsão.

e. Se $N < p + 1$, o que acontece com X^TX e com a RSS mínima? Relacione com o interpolador do Exercício 2.2.

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.11 (CÁLCULO MATRICIAL E EQUAÇÕES NORMAIS)

a. Mostre que $\frac{\partial}{\partial x}(v^Tx) = v$ e que $\frac{\partial}{\partial x}(x^TAx) = 2Ax$ para A simétrica.

b. Deduza as equações normais $X^TX\beta = X^Ty$ e mostre que $2X^TX$ é semidefinida positiva.

c. Monte X^TX e X^Ty explicitamente para $p = 1$ e recupere as equações do Exercício 3.5.

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.12 (É A PROJEÇÃO ORTOGONAL)

EXERCÍCIO 3.12 (Ŷ É A PROJEÇÃO ORTOGONAL)

Seja X a matriz design, $N \times (p+1)$, com colunas linearmente independentes. Escreva $\hat{\beta} = (X^T X)^{-1} X^T y$, $\hat{y} = X\hat{\beta}$, $r = y - \hat{y}$ e $H = X(X^T X)^{-1} X^T$, a ***matriz chapéu***, de modo que $\hat{y} = Hy$.

a. Mostre que H é simétrica e idempotente ($H^2 = H$), que $HX = X$ e que $(I - H)X = 0$.

b. Mostre que r é ortogonal a cada coluna de X, e portanto a todo vetor de $\mathrm{col}(X)$. Reconheça as equações normais nessa afirmação. O que $r \perp \mathbf{1}$ diz sobre a média dos resíduos?

c. Para qualquer β, mostre que $\|y - X\beta\|^2 = \|y - \hat{y}\|^2 + \|\hat{y} - X\beta\|^2$. Conclua, sem derivadas nem Hessiana, que $\hat{\beta}$ minimiza a RSS e que $\hat{y}$ é o ponto de $\mathrm{col}(X)$ mais próximo de y.

d. Suponha agora que as colunas de X são linearmente ***dependentes***. Mostre que $\hat{y}$ continua único, embora $\hat{\beta}$ não seja: a projeção depende do subespaço, não da base. Compare com o Exercício 3.10(c).

e. Mostre que $\mathrm{tr}(H) = p + 1$. Como $\hat{y}_i = \sum_j h_{ij} y_j$, isso diz que, em média, cada observação pesa $(p+1)/N$ na sua própria previsão. Compare com o Exercício 3.5(c).

f. **(Desafio)** Mostre que $0 \le h_{ii} \le 1$. O que significa $h_{ii} = 1$ para a previsão $\hat{y}_i$ e para o resíduo r_i? Ligue com o ponto de borda do Exercício 3.4.

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.13 (A RSS NUNCA AUMENTA COM MAIS PREDITORES)

EXERCÍCIO 3.13 (A RSS NUNCA AUMENTA COM MAIS PREDITORES)

Seja X_1 uma matriz design $N \times q$ e $X_2 = [\,X_1 \;\; Z\,]$ a matriz obtida acrescentando m novas colunas. Sejam RSS_1 e RSS_2 as somas de quadrados mínimas dos dois ajustes, H_1 e H_2 as matrizes chapéu e $r_1 = y - H_1 y$.

a. Mostre que $\mathrm{RSS}_2 \leq \mathrm{RSS}_1$ em uma linha, olhando apenas para os conjuntos sobre os quais cada RSS é minimizada.

b. Prove de novo, geometricamente: $\mathrm{col}(X_1) \subseteq \mathrm{col}(X_2)$, e o ponto mais próximo em um subespaço maior não pode estar mais longe. Use o Exercício 3.12(c).

c. Mostre que $H_2 \hat{y}_1 = \hat{y}_1$, conclua que $\hat{y}_2 - \hat{y}_1 = H_2 r_1$ e daí que $\mathrm{RSS}_1 - \mathrm{RSS}_2 = \|H_2 r_1\|^2$. Deduza que vale a igualdade se, e somente se, $Z^T r_1 = 0$. Traduza: os novos preditores não explicam nada do que ***sobrou*** por explicar.

d. Conclua que R^2 nunca diminui ao acrescentar preditores. Por que, então, RSS e R^2 de ***treino*** não servem para escolher entre modelos aninhados? O que serve?

e. O resultado vale para a RSS de ***teste***? Responda com o Exercício 3.2. Acrescente uma coluna de números puramente aleatórios: a RSS de treino cai. Foi viés que diminuiu? Relacione com o Exercício 2.18(d).

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.14 (GAUSS–MARKOV)

EXERCÍCIO 3.14 (GAUSS–MARKOV)

Suponha $y = X\beta + \varepsilon$ com X fixa de colunas linearmente independentes, $\mathbb{E}[\varepsilon] = 0$ e $\mathrm{Var}(\varepsilon) = \sigma^2 I$.

a. Mostre que $\mathbb{E}[\hat\beta] = \beta$ e $\mathrm{Var}(\hat\beta) = \sigma^2 (X^T X)^{-1}$. Recupere as fórmulas do Exercício 3.7 para $p = 1$.

b. Seja $\tilde\beta = Cy$ outro estimador ***linear*** em y e ***não-viesado*** para todo β. Mostre que $CX = I$.

c. Escreva $C = (X^T X)^{-1} X^T + D$ e mostre que $DX = 0$. Conclua que $\mathrm{Var}(\tilde\beta) = \mathrm{Var}(\hat\beta) + \sigma^2 DD^T$ e, portanto, $\mathrm{Var}(a^T\tilde\beta) \geq \mathrm{Var}(a^T\hat\beta)$ para todo vetor a: mínimos quadrados é o estimador linear não-viesado de menor variância.

d. O estimador ridge também é linear em y e, para $\lambda > 0$, tem variância menor que $\hat\beta$. Isso contradiz (c)? Qual hipótese ele abandona, e o que ganha em troca? Relacione com o trade-off viés-variância.

💡 Dica

TIPO Demonstração NÍVEL Desafio USO DE IA Não recomendado

EXERCÍCIO 3.15 (O OTIMISMO DO ERRO DE TREINO)

EXERCÍCIO 3.15 (O OTIMISMO DO ERRO DE TREINO)

Nas hipóteses do Exercício 3.14, com H a matriz chapéu e $\hat{y} = Hy$.

a. Mostre que $r = (I - H)\varepsilon$: o resíduo não enxerga $X\beta$.

b. Mostre que $\mathbb{E}[\mathrm{RSS}] = \sigma^2(N - p - 1)$. Conclua que $\hat{\sigma}^2 = \mathrm{RSS}/(N - p - 1)$ é um estimador não-viesado de σ^2 e que $\mathbb{E}[\mathrm{MSE}_{\text{treino}}] = \sigma^2\left(1 - \frac{p+1}{N}\right) < \sigma^2$: em média, o erro de treino fica ***abaixo*** do erro irredutível.

c. Tome novas respostas $y^* = X\beta + \varepsilon^*$ nos ***mesmos*** x_i, com ε^* independente de ε. Mostre que $\frac{1}{N}\mathbb{E}\|y^* - \hat{y}\|^2 = \sigma^2\left(1 + \frac{p+1}{N}\right)$.

d. Conclua que a diferença entre erro de teste e erro de treino esperados, o ***otimismo***, é $2\sigma^2(p+1)/N$. Como ela depende de p, de N e de σ^2? Explique com isso por que a RSS de treino do Exercício 3.13 não pode escolher p.

💡 Dica

TIPO Demonstração NÍVEL Desafio USO DE IA Não recomendado

EXERCÍCIO 3.16 (LOOCV SEM REAJUSTAR)

EXERCÍCIO 3.16 (LOOCV SEM REAJUSTAR)

Seja $\hat{\beta}^{(-i)}$ o ajuste de mínimos quadrados sem a observação i, e $\hat{y}_i^{(-i)} = x_i^T \hat{\beta}^{(-i)}$ a previsão para o ponto deixado de fora.

a. Considere o ajuste com ***todas*** as N observações, mas com y_i substituído por $\hat{y}_i^{(-i)}$. Mostre que esse ajuste é exatamente $\hat{\beta}^{(-i)}$.

b. Como $\hat{y} = Hy$ é linear em y, use (a) para mostrar que $\hat{y}_i^{(-i)} = \sum_{j \neq i} h_{ij} y_j + h_{ii}\, \hat{y}_i^{(-i)}$ e, daí,

$$y_i - \hat{y}_i^{(-i)} = \frac{y_i - \hat{y}_i}{1 - h_{ii}}.$$

c. Conclua que o erro de validação cruzada ***leave-one-out*** é $\frac{1}{N} \sum_i \left(\frac{r_i}{1 - h_{ii}} \right)^2$, calculável com um único ajuste. Compare o custo com o dos N ajustes.

d. Interprete: pontos de alta alavancagem (h_{ii} perto de 1) são os que mais penalizam o LOOCV. O que acontece se $h_{ii} = 1$? Use o Exercício 3.12(f).

💡 Dica

TIPO Demonstração NÍVEL Desafio USO DE IA Não recomendado

EXERCÍCIO 3.17 (REGRESSÃO PARCIAL)

EXERCÍCIO 3.17 (REGRESSÃO PARCIAL)

Escreva $X = [\, X_1 \;\; x_2 \,]$, em que x_2 é uma única coluna (digamos, turbidez) e X_1 reúne o intercepto e os demais preditores. Seja H_1 a matriz chapéu de X_1, e defina os resíduos $\tilde{x}_2 = (I - H_1)x_2$ e $\tilde{y} = (I - H_1)y$: o que sobra de x_2 e de y depois de "descontar" X_1.

a. Mostre que o coeficiente $\hat{\beta}_2$ de x_2 na regressão múltipla é o coeficiente da regressão simples, sem intercepto, de $\tilde{y}$ sobre $\tilde{x}_2$:

$$\hat{\beta}_2 = \frac{\tilde{x}_2^T \tilde{y}}{\tilde{x}_2^T \tilde{x}_2}.$$

b. Interprete: $\hat{\beta}_2$ mede o efeito de x_2 ***controlando*** pelos outros preditores. Explique com isso como o coeficiente da turbidez pode ter um sinal na regressão simples e o sinal oposto na múltipla.

c. Quando o coeficiente da regressão múltipla coincide com o da simples? Mostre que basta $X_1^T x_2 = 0$.

d. Mostre que $\mathrm{Var}(\hat{\beta}_2) = \sigma^2 / \|\tilde{x}_2\|^2$. O que acontece quando x_2 é quase uma combinação linear das colunas de X_1? Relacione com o Exercício 3.10 e com o Exercício 3.14(a).

Dica

TIPO Demonstração NÍVEL Desafio USO DE IA Não recomendado

EXERCÍCIO 3.18 (IMPLEMENTANDO O CASO GERAL)

a. Implemente `ols(X, y)` com NumPy: acrescente a coluna de uns e resolva as equações normais com `np.linalg.solve` (não inverta a matriz).

b. Valide contra `ols_p1` do Exercício 3.9.

c. Duplique uma coluna de X e rode de novo. O que acontece? Relacione com o Exercício 3.10.

TIPO Programação USO DE IA Permitido

3.3 Acurácia dos coeficientes

Leitura: seção *Medindo acurácia*, parte *Acurácia dos coeficientes* (erro-padrão, intervalo de confiança, teste de hipótese, estatística t e valor-p).

Você deve saber

Distinguir o coeficiente verdadeiro β_j do estimado $\hat{\beta}_j$, e dizer o que varia de amostra para amostra.

Definir o erro-padrão $\mathrm{SE}(\hat{\beta}_j)$, dizer o que ele mede e do que depende.

Construir e interpretar corretamente um intervalo de confiança de 95%.

Formular $H_0 : \beta_j = 0$, calcular a estatística t e interpretar o valor-p.

Separar significância estatística de relevância prática.

EXERCÍCIO 3.19 (O QUE O ERRO-PADRÃO MEDE?)

a. No modelo $Y = \beta_0 + \beta_1 X + \varepsilon$, quais objetos são fixos e quais são aleatórios: β_1, $\hat{\beta}_1$, x_i, y_i, ε_i? Em relação a qual experimento imaginário se fala em "distribuição de $\hat{\beta}_1$"?

b. Você já viu $\mathrm{SE}(\hat{\beta}_1)$ desenhado: é a largura de qual figura do Exercício 3.4? Que fórmula do Exercício 3.7 ele estima?

c. A fórmula de $\mathrm{SE}(\hat{\beta}_1)$ tem $\sigma^2 = \mathrm{Var}(\varepsilon)$, que ninguém conhece. Pelo que se troca e por que a troca é honesta (Exercício 3.15(b))?

d. Para cada mudança, diga se $\mathrm{SE}(\hat{\beta}_1)$ aumenta, diminui ou não muda: dobrar N mantendo a dispersão dos x_i; medir estações com pH mais variado; usar um laboratório com medições mais precisas; trocar a unidade do pH.

e. É possível reduzir $\mathrm{SE}(\hat{\beta}_1)$ coletando mais ***variáveis*** em vez de mais ***amostras*** ? Em que sentido sim (o que acontece com σ^2?) e em que sentido não (Exercício 3.17(d))?

f. $\mathrm{SE}(\hat{\beta}_1)$ pequeno significa que o modelo prevê bem? Distinga "conhecer β_1 com precisão" de "prever Y com precisão".

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.20 (INTERVALOS DE CONFIANÇA)

EXERCÍCIO 3.20 (INTERVALOS DE CONFIANÇA)

Para o arsênio em μg/L, uma regressão com $N = 660$ estações deu $\hat{\beta}_{\text{pH}} = 15{,}2$ com intervalo de 95% igual a $[10{,}3;\ 20{,}1]$, e $\hat{\beta}_{\text{turb}} = -2{,}1$ com intervalo $[-5{,}2;\ 1{,}0]$.

a. O que é aleatório na frase "o intervalo contém β com probabilidade 95%": o intervalo ou β? Descreva o experimento repetido em que os 95% fazem sentido.

b. Critique: "há 95% de chance de β_{pH} estar entre 10,3 e 20,1" e "95% das estações têm efeito do pH nesse intervalo".

c. Interprete o intervalo do pH, com unidades, para o órgão ambiental. O que o intervalo da turbidez permite concluir? E o que ele ***não*** permite concluir?

d. Se N passar a 2640 estações com a mesma dispersão de pH, aproximadamente quanto encolhe cada intervalo? Use a fórmula do Exercício 3.7.

e. Explique por que a regra "$\hat{\beta} \pm 2\,\text{SE}$" dá aproximadamente 95%, e de onde vem o 2. O que muda se $N = 8$?

f. Além do intervalo para β_1, há um intervalo para $f(x_0) = \beta_0 + \beta_1 x_0$ e outro para uma ***nova*** observação Y em x_0. Ordene os três por largura e explique qual deles não encolhe quando $N \to \infty$. Qual interessa ao laboratório e qual ao órgão ambiental do Seção 1?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.21 (TESTANDO $B_j = 0$)

a. Escreva H_0 e H_1 para a pergunta "a turbidez tem alguma relação com o arsênio?". Por que a hipótese testada é a de ***ausência*** de efeito, e não a de presença?

b. A estatística é $t = \hat{\beta}_j / \mathrm{SE}(\hat{\beta}_j)$. Em palavras: o que ela compara? Por que $\hat{\beta}_j = 3$ pode ser forte evidência contra H_0 em um conjunto de dados e nenhuma evidência em outro?

c. Defina valor-p. Critique cada leitura: "é a probabilidade de H_0 ser verdadeira"; "é a probabilidade de o resultado ter ocorrido por acaso"; "$p = 0{,}30$ prova que a turbidez não importa".

d. O coeficiente da condutividade foi $\hat{\beta} = 0{,}0007$ com $p < 0{,}001$. Ele é significativo? Ele é relevante? Que informação falta para responder a segunda pergunta?

e. Mostre que trocar a unidade de um preditor (por exemplo, mS/cm em vez de μS/cm) multiplica $\hat{\beta}_j$ e $\mathrm{SE}(\hat{\beta}_j)$ pela mesma constante. O que acontece com t e com o valor-p? O que isso diz sobre julgar importância pelo tamanho do coeficiente?

f. Você testa $p = 20$ preditores, todos sem relação alguma com Y, ao nível de 5%. Quantos "significativos" espera encontrar? Que conclusão sobre "o modelo explica alguma coisa" isso invalida, e que estatística resolve o problema?

g. O valor-p do coeficiente linear de X foi $0{,}8$, mas a relação verdadeira é $Y = X^2 + \varepsilon$ com X simétrico em torno de zero. O teste "errou"? O que exatamente ele testou? Relacione com o Exercício 3.35(b).

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.22 (LENDO UMA TABELA DE REGRESSÃO)

EXERCÍCIO 3.22 (LENDO UMA TABELA DE REGRESSÃO)

Regressão do arsênio (μg/L) sobre três preditores, $N = 660$.

TABELA 3.1

COEFICIENTE	$\hat{\beta}$	SE	T	VALOR-P
Intercepto	−12,0	3,1	?	< 0,001
pH	15,2	2,5	?	< 0,001
Turbidez (NTU)	−2,1	1,6	?	0,19
Condutividade (μS/cm)	0,030	0,004	?	< 0,001

a. Complete a coluna t. Confira que os valores-p são coerentes com a regra "$|t| > 2$ é significativo a 5%".

b. Construa o intervalo de 95% para cada coeficiente. Quais contêm zero?

c. Escreva uma frase para o órgão ambiental sobre cada preditor, com unidades e com o cuidado devido a respeito de causalidade (Exercício 3.17(b)).

d. Preveja o arsênio de uma estação com pH 7, turbidez 20 NTU e condutividade 300 μS/cm. Essa previsão tem erro-padrão? Ele é maior ou menor que o erro de uma nova medição nessa estação?

e. Reescreva a linha da condutividade em mS/cm. O que muda e o que não muda?

f. "A turbidez não é significativa, então retiramos do modelo." Que hipótese essa decisão assume sobre o que aconteceria com os outros coeficientes? Quando ela é falsa (Exercício 3.17(c))?

TIPO Prático USO DE IA Não recomendado

EXERCÍCIO 3.23 (ERRO-PADRÃO DE T E NO CASO $p = 1$)

EXERCÍCIO 3.23 (ERRO-PADRÃO, t E F NO CASO $p=1$)

Seja $\hat{\sigma}^2 = \mathrm{RSS}/(N-2)$ e $\mathrm{SE}(\hat{\beta}_1)^2 = \hat{\sigma}^2 / \sum_i (x_i - \bar{x})^2$.

a. Justifique a fórmula a partir do Exercício 3.7(b) e do Exercício 3.15(b). Por que $N-2$ e não N?

b. Mostre que a estatística $t = \hat{\beta}_1 / \mathrm{SE}(\hat{\beta}_1)$ é invariante por mudança de unidade de x ($x \mapsto cx$) e de y ($y \mapsto cy$).

c. Usando o Exercício 3.8(a), mostre que

$$t^2 = \frac{\sum_i (\hat{y}_i - \bar{y})^2}{\mathrm{RSS}/(N-2)} = \frac{(\mathrm{TSS} - \mathrm{RSS})/1}{\mathrm{RSS}/(N-2)},$$

que é a estatística F para $p = 1$. Interprete: t^2 compara o que a reta ***explicou*** com o que ela ***deixou*** por explicar, por grau de liberdade.

d. Mostre que $t^2 = (N-2)\,\frac{R^2}{1-R^2}$. Conclua que, com N grande, qualquer $R^2 > 0$ acaba sendo "significativo". O que isso diz sobre valor-p como medida de acurácia do modelo?

e. **(Desafio)** Se $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, mostre que $\hat{\beta}_1$ é gaussiana e que $(\hat{\beta}_1 - \beta_1)/\sqrt{\sigma^2 / \sum_i (x_i - \bar{x})^2} \sim \mathcal{N}(0,1)$. Por que, ao trocar σ por $\hat{\sigma}$, a distribuição passa a ser t de Student, com caudas mais pesadas? O que acontece com ela quando $N \to \infty$?

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.24 (SIMULANDO O ERRO-PADRÃO E A COBERTURA)

EXERCÍCIO 3.24 (SIMULANDO O ERRO-PADRÃO E A COBERTURA)

Fixe $x_1, \ldots, x_{30}$ e $\beta_0 = 2$, $\beta_1 = 1{,}5$, $\sigma = 2$, como no Exercício 3.4.

a. Repita 2000 vezes: gere y, ajuste com `ols_p1` e guarde $\hat{\beta}_1$ e $\mathrm{SE}(\hat{\beta}_1)$. Compare o desvio padrão dos $\hat{\beta}_1$ com a média dos SE e com a fórmula exata $\sigma / \sqrt{\sum_i (x_i - \bar{x})^2}$.

b. Em cada repetição, construa $\hat{\beta}_1 \pm 2\,\mathrm{SE}(\hat{\beta}_1)$ e conte em que fração das vezes ele contém $1{,}5$. Repita com $N = 8$: a cobertura ainda é 95%? Relacione com o Exercício 3.20(e).

c. Agora ponha $\beta_1 = 0$ (H_0 verdadeira). Guarde t em cada repetição e calcule a fração de $|t| > 2$. Faça um histograma dos t.

d. Gere 20 preditores aleatórios sem relação com y, ajuste com `ols` do Exercício 3.18 e conte quantos têm $|t| > 2$. Repita várias vezes. Confira sua resposta ao Exercício 3.21(f).

TIPO Programação USO DE IA Permitido

3.4 Acurácia do modelo

Leitura: seção *Medindo acurácia*, parte *Acurácia do modelo* (RSE, R^2, estatística F).

Você deve saber

Definir RSE e R^2, dizer em que unidade cada um está e o que cada um mede.

Explicar por que R^2 nunca diminui com mais preditores e o que o R^2 ajustado corrige.

Enunciar a hipótese testada pela estatística F e explicar por que ela não é substituível por p testes t.

Distinguir acurácia do ***modelo*** (treino) de acurácia da ***previsão*** (teste), e as três fontes de erro de uma previsão.

EXERCÍCIO 3.25 (RSE E R^2)

EXERCÍCIO 3.25 (RSE E R^2)

Defina $\mathrm{RSE} = \sqrt{\mathrm{RSS}/(N-p-1)}$ e $R^2 = 1 - \mathrm{RSS}/\mathrm{TSS}$.

a. Em que unidade está cada um? Para o arsênio, o que significa $\mathrm{RSE} = 2{,}2\ \mu$g/L em uma frase? Como julgar se é grande: comparando com o limite legal, com $\bar{y}$ ou com σ?

b. RSE e $\sqrt{\mathrm{MSE}_{\text{treino}}}$ diferem pelo denominador. Qual dos dois é um estimador não-viesado de σ (Exercício 3.15)? Quando a diferença importa?

c. $R^2 = 0{,}30$ é bom ou ruim? Dê um contexto em que é excelente e outro em que é inaceitável. O que R^2 mede, afinal: a qualidade de $\hat{f}$ ou o tamanho de σ^2 relativo à variação de f?

d. Pelo Exercício 3.13, R^2 nunca diminui ao acrescentar preditores. Defina o R^2 ajustado, $1 - \frac{\mathrm{RSS}/(N-p-1)}{\mathrm{TSS}/(N-1)}$, e explique o que ele penaliza. Ele pode ser negativo? Ele substitui a validação cruzada?

e. É possível ter R^2 baixo com todos os coeficientes significativos? E R^2 alto sem nenhum coeficiente significativo? Construa um cenário para cada (pense em N e em colinearidade).

f. R^2 de treino igual a $0{,}95$ garante boa previsão em novas estações? O que pode dar errado, e que medida do Subseção 2.3 você olharia antes de acreditar?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.26 (A ESTATÍSTICA F)

EXERCÍCIO 3.26 (A ESTATÍSTICA F)

Defina $F = \dfrac{(\mathrm{TSS} - \mathrm{RSS})/p}{\mathrm{RSS}/(N-p-1)}$.

a. Escreva H_0 para F. Ela é a mesma de p testes t simultâneos? Em que ela difere de "$\beta_j = 0$ para ***algum*** j"?

b. Sob H_0, numerador e denominador estimam a mesma quantidade. Qual? Conclua que $F \approx 1$ sob H_0 e explique por que F grande é evidência contra ela.

c. Use o Exercício 3.13: a RSS ***sempre*** cai ao acrescentar p preditores. Em que sentido F pergunta se ela caiu "mais do que cairia por acaso"? Relacione com o Exercício 3.15(d).

d. Escreva a versão de F para comparar dois modelos aninhados: o completo, com p preditores, e o reduzido, com $q < p$. O que vai em cada parte da fração? Quando essa comparação é mais adequada do que olhar os $p - q$ testes t individuais?

e. Com $N = 10^6$ estações, obteve-se $F = 3{,}2$ e $p < 0{,}001$. O modelo é útil? O que o F não mede?

f. Por que F pode ser calculada quando $p > N$? O que quebra e como isso se relaciona com o Exercício 3.10(e)?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.27 (TRÊS FONTES DE ERRO EM UMA PREVISÃO)

EXERCÍCIO 3.27 (TRÊS FONTES DE ERRO EM UMA PREVISÃO)

Ajustamos $\hat{f}(x) = \hat{\beta}_0 + \hat{\beta}_1 x$ e queremos prever o arsênio em uma estação nova, x_0.

a. Decomponha o erro $Y_0 - \hat{f}(x_0)$ em três parcelas: a diferença entre a melhor reta e f (a relação pode não ser linear), a diferença entre $\hat{\beta}$ e β (amostra finita) e ε_0. Nomeie cada uma com o vocabulário do Subseção 2.3.

b. Qual das três parcelas o intervalo de confiança para $f(x_0)$ captura? E o intervalo de previsão para Y_0? Qual nenhuma das duas captura?

c. Qual parcela diminui com N, qual diminui com uma classe $\mathcal{G}$ mais flexível, e qual não diminui com nada?

d. Mostre que a variância de $\hat{f}(x_0)$ é $\sigma^2 \left(\frac{1}{N} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2} \right)$ e conclua que o intervalo para $f(x_0)$ é mais largo longe de $\bar{x}$. Por que extrapolar é perigoso mesmo quando o modelo está certo? E quando está errado?

e. Do ponto de vista do ***laboratório***, que só quer parar de medir arsênio, qual das três parcelas mais importa, e que medida do estudo dirigido a estima?

💡 Dica

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.28 (AGURDÁCIA À MÃO)

EXERCÍCIO 3.28 (ACURÁCIA À MÃO)

Para o arsênio (μg/L), $N = 660$ e $\text{TSS} = 5000$. O modelo com pH, turbidez e condutividade deu $\text{RSS} = 3200$; o modelo só com pH deu $\text{RSS} = 3500$; o modelo com os três preditores mais outros 16 parâmetros físico-químicos deu $\text{RSS} = 3150$.

a. Calcule RSE, R^2 e R^2 ajustado dos três modelos. Qual deles o R^2 prefere? E o ajustado?

b. Calcule a estatística F do modelo com três preditores contra o modelo nulo (só intercepto). Ela é grande?

c. Calcule a F do modelo com três preditores contra o modelo só com pH. Turbidez e condutividade, juntas, acrescentam algo? Compare com o valor-p da turbidez na tabela do Exercício 3.22.

d. Calcule a F do modelo com 19 preditores contra o de 3. Os 16 parâmetros extras valem a pena? Que resultado do Exercício 3.13 explica por que a RSS caiu mesmo assim?

e. Se você tivesse que escolher entre os três modelos por validação cruzada, que ordem espera? Justifique com viés e variância.

💡 Dica

TIPO Prático USO DE IA Não recomendado

EXERCÍCIO 3.29 (TABELA DE REGRESSÃO À MÃO)

EXERCÍCIO 3.29 (TABELA DE REGRESSÃO À MÃO)

a. Estenda `ols` do Exercício 3.18 para uma função `summary(X, y)` que devolve, para cada coeficiente, $\hat\beta_j$, $\mathrm{SE}(\hat\beta_j) = \sqrt{\hat\sigma^2 [(X^T X)^{-1}]_{jj}}$ e t_j, além de RSE, R^2, R^2 ajustado e F. Para o valor-p, use a aproximação normal $2\,(1 - \Phi(|t|))$ quando N é grande, ou estime-o por simulação sob H_0.

b. Gere dados com $p = 3$ preditores, dois relevantes e um irrelevante, e $N = 100$. Confira que a tabela identifica o irrelevante e que F é grande.

c. Torne dois preditores relevantes quase colineares (correlação $0{,}99$). O que acontece com os SE, os t e o F? Explique com o Exercício 3.17(d) e responda de novo ao Exercício 3.25(e).

d. Repita (b) 1000 vezes com todos os $\beta_j = 0$ e faça o histograma de F. Que fração ultrapassa o limiar que você usou em (b)?

TIPO Programação USO DE IA Permitido

3.5 Regularização: ridge

Leitura: seções *Regularização* e *Ridge Regression*.

Você deve saber

Escrever a função objetivo do ridge e sua solução fechada.

Explicar o efeito de λ sobre viés, variância e erro de teste.

Explicar por que ridge resolve o problema de $X^T X$ singular.

EXERCÍCIO 3.30 (RIDGE E O TRADE-OFF)

EXERCÍCIO 3.30 (RIDGE E O TRADE-OFF)

a. Complete e justifique: "em relação a mínimos quadrados, ridge é ***mais / menos*** flexível e melhora a previsão quando ***o aumento do viés / a redução da variância*** é menor que ***...***".

b. Com λ crescendo a partir de zero, diga se cada quantidade aumenta sempre, diminui sempre, tem forma de U ou é constante: erro de treino, erro de teste, variância, viés², erro irredutível.

c. Tome $N = p$ e $X = I$ (sem intercepto). Mostre que a solução ridge é $\hat{\beta}_j = y_j/(1+\lambda)$. Interprete a palavra ***encolhimento*** e ligue ao item (b).

d. Por que se padroniza os preditores antes de aplicar ridge? O que aconteceria com um preditor medido em uma unidade mil vezes menor?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.31 (SOLUÇÃO FECHADA E COLUNAS IDÊNTICAS)

Considere ridge sem intercepto: $L(\beta) = (y - X\beta)^T(y - X\beta) + \lambda\beta^T\beta$.

a. Mostre que $\hat{\beta}_{\text{ridge}} = (X^TX + \lambda I)^{-1}X^Ty$ e que $X^TX + \lambda I$ é invertível para todo $\lambda > 0$, mesmo quando X^TX não é. Compare com o Exercício 3.10.

b. Suponha que duas colunas de X são idênticas. Mínimos quadrados tem infinitas soluções; mostre que ridge tem uma única, e que nela os dois coeficientes são iguais.

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.32 (RIDGE POR DENTRO)

EXERCÍCIO 3.32 (RIDGE POR DENTRO)

Ridge sem intercepto, $\hat{\beta}_\lambda = (X^T X + \lambda I)^{-1} X^T y$, com X de dimensão $N \times p$.

a. **Dados aumentados.** Mostre que $\hat{\beta}_\lambda$ é a solução de mínimos quadrados ***ordinários*** para a matriz $\tilde{X} = \begin{pmatrix} X \\ \sqrt{\lambda} I_p \end{pmatrix}$ e o vetor $\tilde{y} = \begin{pmatrix} y \\ 0 \end{pmatrix}$. Interprete as p observações fictícias. Mostre que $\tilde{X}$ tem sempre colunas linearmente independentes, mesmo que X não tenha.

b. **Colunas ortonormais.** Se $X^T X = I$, mostre que $\hat{\beta}_\lambda = \hat{\beta}_{\text{MQ}} / (1 + \lambda)$. Isso generaliza o Exercício 3.30(c).

c. **Viés.** Sob as hipóteses do Exercício 3.14, mostre que $\mathbb{E}[\hat{\beta}_\lambda] = (X^T X + \lambda I)^{-1} X^T X \, \beta$. Conclua que ridge é viesado para todo $\lambda > 0$ e determine para onde o viés vai quando $\lambda \to \infty$.

d. **(Desafio) Variância.** Mostre que $\text{Var}(\hat{\beta}_\lambda) = \sigma^2 (X^T X + \lambda I)^{-1} X^T X \, (X^T X + \lambda I)^{-1}$. Diagonalize $X^T X = Q \Lambda Q^T$ e mostre que os autovalores de $\text{Var}(\hat{\beta}_\lambda)$ são $\sigma^2 \lambda_j / (\lambda_j + \lambda)^2$, decrescentes em λ. Quais direções ridge encolhe mais: as de λ_j grande ou pequeno? Por que isso é bom quando há colinearidade?

e. **(Desafio) Monotonicidade.** Sem calcular nada, mostre que $\lambda \mapsto \|\hat{\beta}_\lambda\|$ é não-crescente e $\lambda \mapsto \text{RSS}(\hat{\beta}_\lambda)$ é não-decrescente. Ligue com as curvas do Exercício 3.30(b).

💡 Dica

TIPO Demonstração NÍVEL Desafio USO DE IA Não recomendado

EXERCÍCIO 3.33 (IMPLEMENTANDO RIDGE)

a. Implemente `ridge(X, y, lam)` pela solução fechada, sem penalizar o intercepto.

b. Gere dados com $p = 5$ preditores fortemente correlacionados e $N = 40$. Para uma grade de λ, tabele $\|\hat{\beta}\|$, o MSE de treino e o MSE de teste.

c. Escolha λ com o `k_fold` do Exercício 2.25. Ele coincide com o mínimo do MSE de teste?

TIPO Programação USO DE IA Permitido

3.6 Além de aproximações lineares

Leitura: seção *Além de aproximações lineares*.

Você deve saber

Explicar que "linear" se refere aos parâmetros, não aos preditores.

Montar a matriz design de modelos polinomiais, com transformações e com interações.

Interpretar coeficientes na presença de interação.

EXERCÍCIO 3.34 (INTERAÇÃO E LINEARIDADE NOS PARÂMETROS)

Considere $\widehat{\text{As}} = \beta_0 + \beta_1\,\text{pH} + \beta_2\,\text{turb} + \beta_3\,\text{pH}\cdot\text{turb}$.

a. O que β_1 mede quando $\beta_3 \neq 0$? Escreva o efeito de aumentar o pH em uma unidade como função da turbidez.

b. Para quais valores de turbidez o efeito do pH é positivo?

c. "$\hat{\beta}_3$ é pequeno, logo a interação não importa." Critique, pensando na escala das variáveis.

d. Para cada modelo, diga se é linear nos parâmetros e, quando for, escreva a matriz design: $\beta_0 + \beta_1 x + \beta_2 x^2$; $\beta_0 + \beta_1 \log x$; $\beta_0 e^{\beta_1 x}$; $\beta_0 + \beta_1 x_1 x_2$.

e. Regressão polinomial de grau d *é* regressão linear. Então por que ela sobreajusta quando d cresce? O que mede a "flexibilidade" aqui?

TIPO Conceitual USO DE IA Não recomendado

EXERCÍCIO 3.35 (POLINÔMIOS E A RSS)

Seja $\mathrm{RSS}(d)$ a soma dos quadrados dos resíduos do ajuste polinomial de grau d a N pontos com x_i distintos.

a. Mostre que $\mathrm{RSS}(d)$ é não-crescente em d e que $\mathrm{RSS}(N-1) = 0$. Junte o Exercício 3.13 com o Exercício 2.3. Que $\mathrm{RSS}(d)$ o Exercício 2.22 mostra?

b. Mostre que, se os x_i são simétricos em torno de 0 (isto é, $-x_i$ também é um dos pontos), então as colunas de potências pares e ímpares são ortogonais. O que isso implica para $\hat{\beta}_1$ ao passar do grau 1 para o grau 2? E ao passar para o grau 3?

c. Por que a matriz $[\,1, x, x^2, \ldots, x^d\,]$ com $x_i \in [0,1]$ tem X^TX quase singular quando d cresce? Usando o Exercício 3.14(a), o que isso faz com a variância dos coeficientes? O que centrar os x_i resolve, e o que não resolve?

💡 Dica

TIPO Demonstração USO DE IA Não recomendado

EXERCÍCIO 3.36 (FECHANDO O CICLO)

a. Escreva `poly_design(x, d)`, que monta a matriz design $[1, x, x^2, \ldots, x^d]$, e use `ols` e `ridge` para ajustar polinômios.

b. Com dados sintéticos de $y = \sin(2\pi x) + \varepsilon$, reproduza a curva em U do Exercício 2.22: MSE de treino e de teste em função de d.

c. Escolha o par (d, λ) por validação cruzada. Compare o polinômio de grau alto com λ bem escolhido ao polinômio de grau ótimo sem regularização. Qual tem menor erro de teste? Explique com viés e variância.

TIPO Programação USO DE IA Permitido