EXERCÍCIO 2.1 (O MODELO Y = f(X) + ε)

a. No problema do arsênio, o que a função f representa? Ela existe mesmo que ninguém a conheça?

b. Mostre que exigir $E[\varepsilon] = 0$ é uma convenção, não uma hipótese: se $E[\varepsilon] = c \neq 0$, redefina f e ε para que valha.

c. Há duas fontes de ε: variáveis relevantes que não foram medidas e o erro de medição do laboratório. Qual delas diminui coletando mais amostras? E coletando mais variáveis? Qual delas nenhum método consegue reduzir?

d. Suponha que Var(ε) dependa de x (rios limpos têm medições mais precisas). O que muda na previsão de f? E na avaliação do erro de uma estimativa f?

EXERCÍCIO 2.2 (INTERPOLAR NÃO É APRENDER)

O polinômio interpolador de grau N - 1 passa por todos os N pontos: seu risco empírico é zero.

a. Por que isso não faz dele uma boa estimativa de f? O que ele "aprende" além de f?

b. Usando o fenômeno de Runge, explique por que aumentar N pode piorar o interpolador, quando um bom método deveria melhorar com mais dados.

c. Que hipótese sobre f e sobre ε tornaria interpolar razoável?

d. Reamostrar apenas o ruído ε (mantendo os x_i) muda muito o interpolador. Que nome esse fenômeno vai receber mais adiante?

EXERCÍCIO 2.5 (O QUE O RISCO EMPÍRICO MEDE?)

a. Em palavras, o que $(1/N) \sum_{i=1}^{N} \ell(y_i, \hat{y}_i)$ mede? Por que é uma média? Que resultado de probabilidade justifica usá-la?

b. O ERM tem dois ingredientes, a perda ℓ e a classe G. Qual deles codifica o que nos importa e qual codifica o que acreditamos sobre f?

c. O que o ERM devolve se G é o conjunto de todas as funções? E se G é o conjunto das funções constantes?

d. Conclua: o risco empírico mede a qualidade do ajuste. Que quantidade mediria aprendizado?

EXERCÍCIO 2.6 (PREVISÃO OU INFERÊNCIA?)

Para o arsênio (em mg/L), o modelo f_A(x) = 15,2 · pH - 2,1 · turbidez - 5 tem erro de teste maior que um kNN com k = 7, f_B.

a. Qual dos dois você entrega ao laboratório que quer parar de medir arsênio? Por quê?

b. Qual você entrega ao órgão ambiental que pergunta "reduzir a turbidez ajuda?"

c. Interprete o coeficiente 15,2, com unidades. O sinal de -2,1 significa que turbidez causa menos arsênio?

d. Por que não há nada análogo a interpretar em f_B?

e. Descreva um cenário em que o modelo com maior erro de teste é a escolha certa.

EXERCÍCIO 2.7 (PARAMÉTRICO VERSUS NÃO-PARAMÉTRICO)

a. Liste vantagens e desvantagens de um método paramétrico frente a um não-paramétrico. Em que situação (tamanho de N, conhecimento sobre f) você prefere cada um?

b. "O kNN não tem parâmetros." Corrija a frase. Qual a diferença entre parâmetro e hiperparâmetro?

c. Por que k não pode ser escolhido minimizando o risco empírico nos dados de treino? Que k sairia?

d. Em que sentido a "quantidade de informação" que o kNN guarda cresce com N, enquanto a da regressão linear não?

EXERCÍCIO 2.10 (VEROSSIMILHANÇA É RISCO EMPÍRICO)

a. Se $\varepsilon \sim N(0, \sigma^2)$, mostre que maximizar a verossimilhança condicional de y_1, ..., y_N dado x_1, ..., x_N é minimizar o risco empírico com perda quadrática.

b. Se ε tem densidade de Laplace (1 / 2b) e^{-|t|/b}, que perda aparece?

c. Conclua: o que a escolha da perda revela sobre a nossa crença a respeito do ruído?

EXERCÍCIO 2.15 (O QUE O MSE MEDE?)

a. No problema do arsênio, em que unidade está o MSE? Por que se costuma reportar a raiz quadrada (RMSE)?

b. MSE_treino e MSE_teste medem coisas diferentes. Nomeie cada uma e explique por que a primeira é sistematicamente otimista.

c. Um modelo tem MSE_teste = 10^{-4}. É bom? Responda comparando com o limite legal de 0,01 mg/L e com Var(ε).

d. Por que nenhum método consegue, em média, MSE de teste abaixo de Var(ε)?

e. O que MSE_treino -> 0 indica sobre o método? E sobre o quanto ele aprendeu?

EXERCÍCIO 2.16 (AS CINCO CURVAS)

Esboce, em um mesmo gráfico com a flexibilidade de G no eixo horizontal, as curvas de viés^2, variância, erro de treino, erro de teste e erro irredutível. Explique a forma de cada curva e por que erro de teste = viés^2 + variância + irredutível. Marque onde ficam o interpolador do Exercício 2.2, a função constante e a regressão linear.

EXERCÍCIO 2.19 (VALIDAÇÃO CRUZADA)

a. Descreva como o k-fold é implementado e quantos ajustes ele exige.

b. Vantagens e desvantagens do k-fold em relação a uma única partição treino/teste.

c. Vantagens e desvantagens do k-fold em relação ao LOOCV. Por que o LOOCV pode ter maior variância, apesar de usar quase todos os dados em cada ajuste?

d. O erro de validação cruzada estima o erro de qual modelo: o ajustado com N pontos ou com N(1 - 1/k)? Isso enviesa a estimativa para cima ou para baixo?

EXERCÍCIO 2.21 (O QUE A REGULARIZAÇÃO FAZ)

Considere o lasso, $\hat{\beta}_\lambda \in \arg\min_\beta \sum_i (y_i - \beta_0 - \beta_1 x_{i1} - \ldots - \beta_d x_{id})^2 + \lambda \sum_{j=1}^d |\beta_j|$, com λ crescendo a partir de zero.

a. Para cada quantidade, diga se ela aumenta sempre, diminui sempre, tem forma de U ou fica constante, e justifique: erro de treino, erro de teste, variância, viés², erro irredutível.

b. Por que β_0 não é penalizado?

c. Se a coluna x for medida em outra unidade (por exemplo, gramas em vez de quilos), a solução muda? O que isso sugere fazer antes de regularizar?

EXERCÍCIO 2.23 (ERRO REDUTÍVEL E IRREDUTÍVEL)

Fixe x e seja $Y(x) = f(x) + \varepsilon$. Mostre que

$$E[(Y(x) - \hat{f}(x))^2] = E[(f(x) - \hat{f}(x))^2] + \mathrm{Var}(\varepsilon),$$

indicando exatamente onde se usa $E[\varepsilon] = 0$ e onde se usa a independência entre ε e $\hat{f}(x)$. Por que $\hat{f}(x)$ é uma variável aleatória?

EXERCÍCIO 2.24 (VIÉS E VARIÂNCIA)

Mostre que

$$E[(f(x) - \hat{f}(x))^2] = (f(x) - E[\hat{f}(x)])^2 + \mathrm{Var}(\hat{f}(x)).$$

Em relação a que distribuição são tomadas essas esperanças?

EXERCÍCIO 2.27 (O QUE A PERDA 0-1 MEDE?)

a. Por que $y - \hat{y}$ não faz sentido quando $y \in$ {contaminada, não-contaminada}? O que a perda $1\{y \neq \hat{y}\}$ mede em seu lugar?

b. Apenas 3% das estações são contaminadas. Qual a taxa de erro do classificador constante "não-contaminada"? Ele é bom?

c. Escreva uma perda assimétrica do capítulo (errar uma estação contaminada custa 2, errar uma limpa custa 1) como uma matriz 2×2 e calcule o risco empírico do classificador constante sob ela.

d. Que perda tornaria um classificador com taxa de erro 20% preferível ao constante? O que isso diz sobre "taxa de erro" como medida de performance?

EXERCÍCIO 2.28 (O CLASSIFICADOR DE BAYES COMO BARREIRA)

a. Defina o classificador de Bayes.

b. Mostre que ele minimiza o risco de classificação equivocada definida como:
$R(\hat{Y}) = P(Y \neq \hat{Y})$

c. Por que ele não pode ser usado na prática? O que um método de aprendizado tenta fazer em relação a ele?

EXERCÍCIO 3.2 (LINEAR OU CÚBICO?)

Suponha que a relação verdadeira seja $Y = \beta_0 + \beta_1 X + \varepsilon$ e que ajustemos, aos mesmos dados, uma reta e um polinômio cúbico.

a. Qual dos dois tem menor RSS de treino, ou não é possível dizer? Justifique.

b. E RSS de teste?

c. Repita (a) e (b) supondo que a relação verdadeira é não-linear, mas não sabemos o quanto.

EXERCÍCIO 3.5 (EQUAÇÕES NORMAIS PARA P = 1)

a. Derive as equações normais para $RSS(\beta_0, \beta_1)$ e resolva-as, obtendo $\hat{\beta}_1$ e $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$.

b. Conclua que a reta ajustada passa por $(\bar{x}, \bar{y})$ e que os resíduos satisfazem $\sum_i r_i = 0$ e $\sum_i x_i r_i = 0$.

c. No ajuste sem intercepto, mostre que $\hat{y}_i = \sum_{i'} a_{i'} y_{i'}$ e encontre os $a_{i'}$. Em que sentido "a previsão é uma combinação linear dos y"? Que $y_{i'}$ pesam mais?

EXERCÍCIO 3.6 (O PONTO CRÍTICO É MÍNIMO)

Mostre que a Hessiana de $RSS(\beta_0, \beta_1)$ é definida positiva se, e somente se, existem i, j com $x_i \neq x_j$. O que acontece com $\hat{\beta}$ quando todos os x_i são iguais? Interprete geometricamente. 💡 Dica

EXERCÍCIO 3.7 (MÉDIA E VARIÂNCIA DE $\hat{\beta}_1$)

Suponha $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ com os x_i fixos e os ε_i independentes, de média zero e variância σ^2.

a. Mostre que $\hat{\beta}_1 = \sum_i w_i y_i$ com $w_i = (x_i - \bar{x}) / \sum_j (x_j - \bar{x})^2$. Onde se usa $\sum_i w_i = 0$?

b. Mostre que $E[\hat{\beta}_1] = \beta_1$ e $Var(\hat{\beta}_1) = \sigma^2 / \sum_i (x_i - \bar{x})^2$.

c. Interprete: o que acontece com a variância quando N cresce? E quando os x_i ficam mais espalhados? Relacione com o que você observou no Exercício 3.4.

d. Mostre que $E[\hat{\beta}_0] = \beta_0$ e $Var(\hat{\beta}_0) = \sigma^2 (1/N + \bar{x}^2 / \sum_i (x_i - \bar{x})^2)$. Por que centrar os x_i torna $\hat{\beta}_0$ mais preciso?

EXERCÍCIO 3.10 (IDENTIFICABILIDADE)

a. Mostre que $X^T X$ é invertível se, e somente se, as colunas de X são linearmente independentes.

b. Traduza a condição em termos dos preditores.

c. Dê um exemplo com $p = 2$ em que uma coluna é múltipla da outra. Quantas soluções o problema de mínimos quadrados tem? O ajuste $\hat{y} = X\hat{\beta}$ é único?

d. Explique por que (c) é um problema para inferência, mas não necessariamente para previsão.

e. Se $N < p + 1$, o que acontece com X^TX e com a RSS mínima? Relacione com o interpolador do Exercício 2.2.

EXERCÍCIO 3.11 (CÁLCULO MATRICIAL E EQUAÇÕES NORMAIS)

a. Mostre que $\partial/\partial x\ (v^T x) = v$ e que $\partial/\partial x\ (x^T A x) = 2Ax$ para A simétrica.

b. Deduza as equações normais $X^TX\ \beta = X^Ty$ e mostre que $2X^TX$ é semidefinida positiva.

c. Monte X^TX e X^Ty explicitamente para $p = 1$ e recupere as equações do Exercício 3.5.

EXERCÍCIO 3.30 (RIDGE E O TRADE-OFF)

a. Complete e justifique: "em relação a mínimos quadrados, ridge é mais / menos flexível e melhora a previsão quando o aumento do viés / a redução da variância é menor que ...".

b. Com λ crescendo a partir de zero, diga se cada quantidade aumenta sempre, diminui sempre, tem forma de U ou é constante: erro de treino, erro de teste, variância, viés^2, erro irredutível.

c. Tome $N = p$ e $X = I$ (sem intercepto). Mostre que a solução ridge é $\hat{\beta}_j = y_j / (1 + \lambda)$. Interprete a palavra encolhimento e ligue ao item (b).

d. Por que se padroniza os preditores antes de aplicar ridge? O que aconteceria com um preditor medido em uma unidade mil vezes menor?

EXERCÍCIO 3.31 (SOLUÇÃO FECHADA E COLUNAS IDÊNTICAS)

Considere ridge sem intercepto: $L(\beta) = (y - X\beta)^T(y - X\beta) + \lambda\ \beta^T\beta$.

a. Mostre que $\hat{\beta}_{ridge} = (X^TX + \lambda I)^{-1}\ X^Ty$ e que $X^TX + \lambda I$ é invertível para todo $\lambda > 0$, mesmo quando X^TX não é. Compare com o Exercício 3.10.

b. Suponha que duas colunas de X são idênticas. Mínimos quadrados tem infinitas soluções; mostre que ridge tem uma única, e que nela os dois coeficientes são iguais.

EXERCÍCIO 3.35 (POLINÔMIOS E A RSS)

Seja RSS(d) a soma dos quadrados dos resíduos do ajuste polinomial de grau d a N pontos com x_i distintos.

a. Mostre que RSS(d) é não-crescente em d e que RSS(N - 1) = 0. Junte o Exercício 3.13 com o Exercício 2.3. Que RSS(d) o Exercício 2.22 mostra?

b. Mostre que, se os x_i são simétricos em torno de 0 (isto é, -x_i também é um dos pontos), então as colunas de potências pares e ímpares são ortogonais. O que isso implica para β_1 ao passar do grau 1 para o grau 2? E ao passar para o grau 3?

c. Por que a matriz $[1, x, x^2, ..., x^d]$ com $x_i \in [0, 1]$ tem X^TX quase singular quando d cresce? Usando o Exercício 3.14(a), o que isso faz com a variância dos coeficientes? O que centrar os x_i resolve, e o que não resolve?