Estudo Dirigido I — Soluções Detalhadas

Regressão Linear: Tópico 3.4 ao Final (Exercícios 3.23 a 3.36)

Curso: Aprendizado de Máquina I (MD22) | **Instituição:** IMPA Tech

Apresentação da Parte II

Este documento traz as resoluções completas e fundamentadas do Estudo Dirigido I a partir do **Tópico 3.4 (Acurácia do modelo)** até o encerramento do capítulo de **Regressão Linear** (Tópico 3.6). Em estrita conformidade com as orientações do curso:

- Todos os **enunciados originais** foram integralmente preservados em caixas destacadas.
- Para os **Exercícios de Programação** (3.23, 3.28, 3.32 e 3.35), apresenta-se o enunciado completo acompanhado exclusivamente de uma **discussão e fundamentação teórica rigorosa**, sem inserção de código de implementação.
- Para os **Exercícios Conceituais, Demonstrações e Práticos**, são fornecidas demonstrações algébricas passo a passo, deduções matriciais e interpretações conceituais aprofundadas.

Contents

1 Acurácia do Modelo (Tópico 3.4) 1

2 Regularização: Ridge (Tópico 3.5) 8

3 Além de Aproximações Lineares (Tópico 3.6) 11

---

1 Acurácia do Modelo (Tópico 3.4)

Exercício 3.23 — Simulação de Acurácia do Estimador e Cobertura *[Exercício de Programação]*

Fixe $x_1, \ldots, x_{30}$, $\beta_0 = 2$, $\beta_1 = 1.5$, $\sigma = 2$, como no Exercício 3.4.
a. Repita 2000 vezes: gere y, ajuste com `ols_p1` e guarde $\hat{\beta}_1$ e $\mathrm{SE}(\hat{\beta}_1)$. Compare o desvio padrão dos $\hat{\beta}_1$ com a média dos SE e com a fórmula exata $\sigma/\sqrt{\sum(x_i - \bar{x})^2}$.
b. Em cada repetição, construa $\hat{\beta}_1 \pm 2\,\mathrm{SE}(\hat{\beta}_1)$ e conte em que fração das vezes ele contém 1.5. Repita com $N = 8$: a cobertura ainda é 95%? Relacione com o Exercício 3.20(e).
c. Agora ponha $\beta_1 = 0$ (H_0 verdadeira). Guarde t em cada repetição e calcule a fração de $|t| > 2$. Faça um histograma dos t.
d. Gere 20 preditores aleatórios sem relação com y, ajuste com `ols` do Exercício 3.18 e conte quantos têm $|t| > 2$. Repita várias vezes. Confira sua resposta ao Exercício 3.21(f).

Comentário Teórico

1. **Propriedades Amostrais do Estimador ($\hat{\beta}_1$):** A variância teórica do estimador MQO em regressão simples é dada por $\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum(x_i-\bar{x})^2}$. Em um experimento Monte Carlo com $M = 2000$ réplicas, o desvio padrão amostral dos estimadores $\hat{\beta}_1^{(m)}$ converge para a raiz da variância teórica pelo Teorema Central do Limite. Além disso, a média dos erros-padrão estimados $\text{SE}(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{\sum(x_i-\bar{x})^2}}$ coincide com esse valor, pois $\hat{\sigma}^2 = \frac{\text{RSS}}{N-2}$ é um estimador não-viesado de σ^2.

2. **Cobertura do Intervalo e Tamanho Amostral:** A aproximação $95\% \approx \hat{\beta}_1 \pm 2\,\text{SE}(\hat{\beta}_1)$ baseia-se no quantil 1.96 da distribuição Normal Padrão. Para $N = 30$, os graus de liberdade $N-2 = 28$ tornam a distribuição t_{28} muito próxima da Normal, mantendo a taxa de cobertura efetiva em torno de 95%. Contudo, para $N = 8$ ($N-2 = 6$ graus de liberdade), a distribuição t_6 possui caudas significativamente mais pesadas ($t_{0.975,6} = 2.447$). Usar o multiplicador 2 resulta em subcobertura (a taxa de cobertura real cai para aproximadamente 91.5%), ilustrando a necessidade de utilizar o quantil correto da distribuição t de Student em amostras pequenas.

3. **Distribuição Sob a Hipótese Nula (H_0):** Quando $\beta_1 = 0$, a estatística $t = \frac{\hat{\beta}_1}{\text{SE}(\hat{\beta}_1)}$ segue exatamente a distribuição t_{N-2}. O histograma empírico de t exibe simetria em torno de zero, e a fração de rejeições com $|t| > 2$ aproxima-se do nível de significância nominal $\alpha \approx 0.05$.

4. **Multiplicidade e Falsos Positivos:** Ao testar $p = 20$ preditores independentes e irrelevantes ($\beta_j = 0$) ao nível $\alpha = 0.05$, a probabilidade de rejeitar individualmente cada hipótese nula é 5%. A quantidade esperada de falsos positivos é $20 \times 0.05 = 1$. A probabilidade de obter pelo menos um falso positivo no modelo completo é $1 - (1 - 0.05)^{20} \approx 64.2\%$. Isso invalida a inferência ingênua baseada em múltiplos testes t isolados e fundamenta a necessidade da estatística F global.

Exercício 3.24 — Acurácia do Modelo: RSE e R^2

Defina $\text{RSE} = \sqrt{\frac{\text{RSS}}{N-p-1}}$ e $R^2 = 1 - \frac{\text{RSS}}{\text{TSS}}$.

a. Em que unidade está cada um? Para o arsênio, o que significa $\text{RSE} = 2.2\,\mu\text{g/L}$ em uma frase? Como julgar se é grande: comparando com o limite legal, com $\bar{y}$ ou com σ?

b. RSE e $\text{MSE}_{\text{treino}}$ diferem pelo denominador. Qual dos dois é um estimador não-viesado de σ^2? Quando a diferença importa?

c. $R^2 = 0.30$ é bom ou ruim? Dê um contexto em que é excelente e outro em que é inaceitável. O que R^2 mede, afinal?

d. Pelo Exercício 3.13, R^2 nunca diminui ao acrescentar preditores. Defina o R^2 ajustado, $R^2_{\text{adj}} = 1 - \frac{\text{RSS}/(N-p-1)}{\text{TSS}/(N-1)}$, e explique o que ele penaliza. Ele pode ser negativo? Ele substitui a validação cruzada?

e. É possível ter R^2 baixo com todos os coeficientes significativos? E R^2 alto sem nenhum coeficiente significativo? Construa um cenário para cada.

f. R^2 de treino igual a 0.95 garante boa previsão em novas estações? O que pode dar errado, e que medida da Subseção 2.3 você olharia antes de acreditar?

Resolução

a. O **RSE** (Erro Padrão dos Resíduos) é medido nas mesmas unidades da variável resposta Y (no problema do arsênio, μg/L). O R^2 é uma quantidade adimensional expressa como uma fração ou porcentagem no intervalo $[0, 1]$.
Significado: $\text{RSE} = 2.2\,\mu\text{g/L}$ indica que o desvio médio típico entre os valores observados de

concentração de arsênio e as previsões do modelo é de aproximadamente $2.2\,\mu$g/L.
Avaliação: Para julgar se é elevado, deve-se comparar com a magnitude dos dados ($\bar{y}$), com o desvio padrão total de Y, e fundamentalmente com a tolerância regulatória/norma de saúde pública (ex.: se o limite de potabilidade for $10\,\mu$g/L, um erro de $2.2\,\mu$g/L representa 22% do limite total, sendo considerável).

b. O estimador não-viesado da variância do erro σ^2 é $\text{RSE}^2 = \frac{\text{RSS}}{N-p-1}$ (conforme provado no Exercício 3.15, pois a perda de $p+1$ graus de liberdade corrige o viés de otimismo da minimização de mínimos quadrados). Em contraste, $\text{MSE}_{\text{treino}} = \frac{\text{RSS}}{N}$ subestima sistematicamente σ^2. A diferença entre ambos torna-se substancial quando a dimensão p é grande em relação a N (isto é, p/N não é negligenciável).

c. A interpretação de $R^2 = 0.30$ (30% da variância explicada) depende inteiramente do domínio:

- *Excelente:* Em estudos comportamentais, epidemiológicos ou ecológicos de campo, onde a variabilidade biológica/ambiental inata (σ^2) é massiva.
- *Inaceitável:* Em engenharia de precisão, física experimental ou calibração de sensores analíticos de laboratório, onde se exige $R^2 > 0.99$.

O R^2 mede a proporção da variação total de Y que é explicada pela regressão linear relativa à variabilidade total observada. Um R^2 baixo reflete a preponderância do ruído irredutível $\text{Var}(\epsilon)$, mas não significa necessariamente que a função estimada $\hat{f}$ seja inadequada.

d. O R^2 ajustado é definido por:

$$R^2_{\text{adj}} = 1 - \frac{\text{RSS}/(N-p-1)}{\text{TSS}/(N-1)}$$

Ele penaliza a inclusão de variáveis desnecessárias através da divisão da RSS pelos seus graus de liberdade residuais $N-p-1$. Adicionar uma nova variável reduz a RSS, porém incrementa p; se a redução na RSS for insuficiente para compensar a perda de um grau de liberdade, R^2_{adj} diminui.
Valor Negativo: Pode ser negativo se o modelo for tão fraco que $\frac{\text{RSS}}{N-p-1} > \frac{\text{TSS}}{N-1}$.
Validação Cruzada: Não substitui a validação cruzada, pois o R^2_{adj} é um ajuste analítico sob hipóteses lineares no treino, ao passo que a validação cruzada avalia a capacidade de generalização empírica em dados não vistos sem assumir especificações rígidas.

e.

- *R^2 baixo com coeficientes significativos:* Ocorre quando o tamanho amostral N é extremamente grande ($N \to \infty$). Os erros-padrão $\text{SE}(\hat{\beta}_j) \propto 1/\sqrt{N}$ tornam-se insignificantes, gerando estatísticas t elevadas e valores-$p < 0.001$, embora a relação explique apenas uma fração minúscula da variância (ex.: $R^2 = 0.02$).
- *R^2 alto sem coeficientes significativos:* Ocorre em cenários de forte multicolinearidade entre os preditores. O modelo explica a variância global ($R^2 = 0.90$, F alto), mas a inflação da variância em $(X^TX)^{-1}$ amplia os erros-padrão $\text{SE}(\hat{\beta}_j)$, fazendo com que nenhum teste t individual alcance significância estatística.

f. Não. Um $R^2_{\text{treino}} = 0.95$ pode derivar de sobreajuste (*overfitting*), no qual o modelo memoriza o ruído dos dados de amostragem (ex.: polinômio de grau alto). Deve-se examinar o erro de teste estimado por validação cruzada ($\text{MSE}_{\text{teste}}$ ou LOOCV) antes de confiar na capacidade preditiva.

Exercício 3.25 — A Estatística F

Defina $F = \frac{(\text{TSS}-\text{RSS})/p}{\text{RSS}/(N-p-1)}$.
a. Escreva H_0 para F. Ela é a mesma de p testes t simultâneos? Em que ela difere de "$p < 0.05$ para algum j"?
b. Sob H_0, numerador e denominador estimam a mesma quantidade. Qual? Conclua que $F \approx 1$ sob H_0 e explique por que F grande é evidência contra ela.
c. Use o Exercício 3.13: a RSS sempre cai ao acrescentar p preditores. Em que sentido F pergunta se ela caiu "mais do que cairia por acaso"?
d. Escreva a versão de F para comparar dois modelos aninhados: o completo (p preditores) e o reduzido ($q < p$). O que vai em cada parte da fração?
e. Com $N = 106$ estações, obteve-se $F = 3.2$ e $p < 0.001$. O modelo é útil? O que o F não mede?
f. Por que F não pode ser calculada quando $p > N$? O que quebra e como isso se relaciona com o Exercício 3.10(e)?

Resolução

a. A hipótese nula do teste F global é:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0 \quad \text{contra} \quad H_1 : \text{ao menos um } \beta_j \neq 0$$

Não é equivalente a p testes t individuais. Testar p coeficientes isoladamente ao nível $\alpha = 0.05$ infla a taxa de erro Tipo I da família de testes para $1 - (0.95)^p$. A estatística F avalia a associação conjunta de todos os preditores simultaneamente, mantendo a taxa de erro Tipo I global exatamente em α.

b. Sob H_0, a variável resposta Y não depende de nenhum dos preditores. O numerador $\frac{\text{TSS}-\text{RSS}}{p}$ e o denominador $\frac{\text{RSS}}{N-p-1}$ constituem dois estimadores independentes e não-viesados da variância do erro σ^2. Portanto:

$$\mathbb{E}\left[\frac{\text{TSS} - \text{RSS}}{p}\right] = \sigma^2 \quad \text{e} \quad \mathbb{E}\left[\frac{\text{RSS}}{N-p-1}\right] = \sigma^2 \implies F \approx 1 \text{ sob } H_0$$

Sob a hipótese alternativa, a presença de coeficientes não nulos $\beta_j \neq 0$ adiciona uma componente quadrática positiva ao numerador, fazendo com que $\mathbb{E}[\text{Numerador}] > \sigma^2$ e resultando em $F \gg 1$.

c. Conforme o Exercício 3.15(d), adicionar p preditores aleatórios puros reduz a RSS esperada por um montante de $p\sigma^2$ devido ao ajuste ao ruído. A estatística F quantifica a razão entre a redução observada da RSS por parâmetro adicional e a variância residual por grau de liberdade $\hat{\sigma}^2$; ela testa se a queda na RSS foi estatisticamente superior ao decréscimo estocástico esperado por mero acaso.

d. Para comparar o modelo completo (p preditores) contra um modelo reduzido aninhado (q preditores, onde $q < p$):

$$F = \frac{(\text{RSS}_{\text{red}} - \text{RSS}_{\text{comp}})/(p-q)}{\text{RSS}_{\text{comp}}/(N-p-1)}$$

O numerador mede o ganho de ajuste por parâmetro adicional ao expandir de q para p preditores, enquanto o denominador é o estimador não-viesado de σ^2 do modelo completo. Essa comparação é ideal para avaliar o impacto conjunto de grupos de preditores (como variáveis dummy de fatores categóricos ou termos polinomiais).

e. O resultado $F = 3.2$ com $p < 0.001$ indica significância estatística (rejeita-se H_0), porém com $N = 106$, um valor de F modesto pode corresponder a um R^2 baixo. A estatística F não mede o poder preditivo em novos dados, a presença de viés de especificação ou a relevância prática.

f. Quando $p \geq N$ (ou $p+1 > N$), o número de parâmetros excede o tamanho amostral. As colunas da matriz design X tornam-se linearmente dependentes, X^TX torna-se singular (não-invertível) e o modelo interpola perfeitamente os dados, resultando em $\text{RSS}_{\text{comp}} = 0$. Como o denominador da fração de F torna-se zero, a estatística F não pode ser calculada (indeterminação de divisão por zero).

Exercício 3.26 — Decomposição do Erro de Previsão

Ajustamos $\hat{f}(x) = \hat{\beta}_0 + \hat{\beta}_1 x$ e queremos prever o arsênio em uma estação nova, x_0.
a. Decomponha o erro $Y_0 - \hat{f}(x_0)$ em três parcelas: viés do modelo, variância da estimativa e erro irredutível. Nomeie cada uma com o vocabulário da Subseção 2.3.
b. Qual das três parcelas o intervalo de confiança para $f(x_0)$ captura? E o intervalo de previsão para Y_0? Qual nenhuma das duas captura?
c. Qual parcela diminui com N, qual diminui com uma classe $\mathcal{G}$ mais flexível, e qual não diminui com nada?
d. Mostre que a variância de $\hat{f}(x_0)$ é $\sigma^2\left(\frac{1}{N} + \frac{(x_0-\bar{x})^2}{\sum(x_i-\bar{x})^2}\right)$ e conclua que o intervalo para $f(x_0)$ é mais largo longe de $\bar{x}$. Por que extrapolar é perigoso?
e. Do ponto de vista do laboratório, qual das três parcelas mais importa, e que medida do estudo dirigido a estima?

Resolução

a. O erro de previsão para uma nova observação $Y_0 = f(x_0) + \epsilon_0$ decomponha-se como:

$$Y_0 - \hat{f}(x_0) = \underbrace{\left[f(x_0) - \mathbb{E}[\hat{f}(x_0)]\right]}_{\text{1. Vies do Modelo (Erro de Especificacao)}} + \underbrace{\left[\mathbb{E}[\hat{f}(x_0)] - \hat{f}(x_0)\right]}_{\text{2. Variancia da Estimativa (Erro Amostral)}} + \underbrace{\epsilon_0}_{\text{3. Erro Irredutivel}}$$

b.
- O **intervalo de confiança** para $f(x_0)$ captura apenas a incerteza da estimativa (Variância da Estimativa).
- O **intervalo de previsão** para Y_0 captura a Variância da Estimativa *somada* ao Erro Irredutível (σ^2).
- Nenhuma das duas construções padrão captura o Viés do Modelo (pois ambas pressupõem que a especificação linear seja a verdadeira forma funcional).

c.
- Diminui com N: A Variância da Estimativa ($\text{Var}(\hat{f}(x_0)) \propto 1/N$).
- Diminui com maior flexibilidade ($\mathcal{G}$): O Viés do Modelo.
- Não diminui com nada: O Erro Irredutível ($\sigma^2 = \text{Var}(\epsilon)$).

d. Demonstração da Variância: Como $\hat{f}(x_0) = \bar{Y} + \hat{\beta}_1(x_0 - \bar{x})$, e sabendo que $\bar{Y} = \frac{1}{N}\sum Y_i$ e $\hat{\beta}_1 = \frac{\sum(x_i-\bar{x})Y_i}{\sum(x_i-\bar{x})^2}$ são não-correlacionados sob os pressupostos clássicos ($\text{Cov}(\bar{Y}, \hat{\beta}_1) = 0$):

$$\text{Var}(\hat{f}(x_0)) = \text{Var}(\bar{Y}) + (x_0-\bar{x})^2\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{N} + (x_0-\bar{x})^2\frac{\sigma^2}{\sum(x_i-\bar{x})^2} = \sigma^2\left[\frac{1}{N} + \frac{(x_0-\bar{x})^2}{\sum(x_i-\bar{x})^2}\right]$$

Conclusão: O termo $(x_0 - \bar{x})^2$ no numerador amplia quadraticamente a variância à medida que x_0 se distanciando do centro dos dados de treino $\bar{x}$, alargando as faixas do intervalo de confiança.
Perigo de Extrapolação: Mesmo sob especificação correta, a incerteza estocástica explode fora do domínio de amostragem. Se o modelo sofrer de erro de especificação (viés), pequenos Desvios dentro da região dos dados convertem-se em erros desastrosos na extrapolação.

e. Para o laboratório que pretende substituir a medição analítica de Y_0 pela previsão $\hat{f}(x_0)$, a quantidade crítica é o **Erro Total de Previsão Individual** (Erro Irredutível + Variância + Viés). A medida ideal que estima esse erro em novas observações é o erro de validação cruzada ($\text{RMSE}_{\text{teste}}$ / LOOCV) ou o erro quadrático médio de previsão.

Exercício 3.27 — Comparando Modelos de Arsênio

Dados: $N = 660$, TSS $= 5000$.
• Modelo 1 (3 preditores: pH, turbidez, condutividade): $p = 3, \text{RSS} = 3200$.
• Modelo 2 (apenas pH): $p = 1, \text{RSS} = 3500$.
• Modelo 3 (19 preditores: 3 + 16 adicionais): $p = 19, \text{RSS} = 3150$.
a. Calcule RSE, R^2 e R^2_{adj} dos três modelos. Qual deles o R^2 prefere? E o R^2_{adj}?
b. Calcule a estatística F do modelo com três preditores contra o modelo nulo. Ela é grande?
c. Calcule a F do modelo com três preditores contra o modelo só com pH. Turbidez e condutividade juntas acrescentam algo?
d. Calcule a F do modelo com 19 preditores contra o de 3. Os 16 parâmetros extras valem a pena? Que resultado do Exercício 3.13 explica por que a RSS caiu mesmo assim?
e. Se você tivesse que escolher entre os três modelos por validação cruzada, que ordem espera? Justifique com viés e variância.

Resolução com Cálculos Explícitos

a. Fórmulas aplicadas com $N = 660$, $N - 1 = 659$, TSS $= 5000$:

$$\text{RSE} = \sqrt{\frac{\text{RSS}}{N-p-1}}, \quad R^2 = 1 - \frac{\text{RSS}}{\text{TSS}}, \quad R^2_{\text{adj}} = 1 - \frac{\text{RSS}/(N-p-1)}{\text{TSS}/(N-1)}$$

- **Modelo 2** ($p = 1$)**:**

$$\text{RSE} = \sqrt{\frac{3500}{658}} = \sqrt{5.31915} \approx \mathbf{2.3063}$$

$$R^2 = 1 - \frac{3500}{5000} = \mathbf{0.3000} \quad (30.00\%)$$

$$R^2_{\text{adj}} = 1 - \frac{3500/658}{5000/659} = 1 - \frac{5.31915}{7.58725} \approx \mathbf{0.2989} \quad (29.89\%)$$

- **Modelo 1** ($p = 3$)**:**

$$\text{RSE} = \sqrt{\frac{3200}{656}} = \sqrt{4.87805} \approx \mathbf{2.2086}$$

$$R^2 = 1 - \frac{3200}{5000} = \mathbf{0.3600} \quad (36.00\%)$$

$$R^2_{\text{adj}} = 1 - \frac{3200/656}{5000/659} = 1 - \frac{4.87805}{7.58725} \approx \mathbf{0.3571} \quad (35.71\%)$$

- **Modelo 3** ($p = 19$)**:**

$$\text{RSE} = \sqrt{\frac{3150}{640}} = \sqrt{4.92188} \approx \mathbf{2.2185}$$

$$R^2 = 1 - \frac{3150}{5000} = \mathbf{0.3700} \quad (37.00\%)$$

$$R^2_{\text{adj}} = 1 - \frac{3150/640}{5000/659} = 1 - \frac{4.92188}{7.58725} \approx \mathbf{0.3513} \quad (35.13\%)$$

Conclusão (a): O R^2 prefere o **Modelo 3** (37%), pois R^2 é monotonicamente não-decrescente em p. O R^2_{adj} prefere o **Modelo 1** (35.71%), pois penaliza adequadamente a inclusão dos 16 preditores irrelevantes do Modelo 3.

b. Teste F do Modelo 1 ($p = 3$) contra o Modelo Nulo ($q = 0, \text{RSS}_{\text{nulo}} = \text{TSS} = 5000$):

$$F = \frac{(\text{TSS} - \text{RSS}_1)/3}{\text{RSS}_1/656} = \frac{(5000 - 3200)/3}{3200/656} = \frac{600}{4.87805} \approx \mathbf{123.00}$$

O valor $F \approx 123.0$ é extremamente elevado, rejeitando com folga a hipótese nula ($p \ll 0.001$).

c. Teste F do Modelo 1 ($p = 3$) contra o Modelo 2 ($q = 1$):

$$F = \frac{(\text{RSS}_2 - \text{RSS}_1)/(3-1)}{\text{RSS}_1/656} = \frac{(3500 - 3200)/2}{3200/656} = \frac{150}{4.87805} \approx \mathbf{30.75}$$

Como o valor crítico $F_{2,656,0.05} \approx 3.00$, $F = 30.75$ é altamente significativo. Turbidez e condutividade conjuntamente adicionam poder explicativo relevante.

d. Teste F do Modelo 3 ($p = 19$) contra o Modelo 1 ($q = 3$):

$$F = \frac{(\text{RSS}_1 - \text{RSS}_3)/(19-3)}{\text{RSS}_3/640} = \frac{(3200 - 3150)/16}{3150/640} = \frac{3.125}{4.92188} \approx \mathbf{0.6349}$$

Como $F = 0.635 < 1$, o teste não é significativo ($p \approx 0.855$). Os 16 parâmetros adicionais não valem a pena. A queda de 3200 para 3150 na RSS é puramente fruto da propriedade geométrica do Exercício 3.13 (a projeção sobre um subespaço maior nunca aumenta a RSS residual).

e. Na Validação Cruzada (CV), a ordem esperada de desempenho (do menor para o maior erro de teste) é:

$$\text{Modelo 1 (3 preditores)} < \text{Modelo 2 (apenas pH)} < \text{Modelo 3 (19 preditores)}$$

O Modelo 2 sofre de subajuste (viés elevado por ignorar a condutividade). O Modelo 3 sofre de sobreajuste (variância desnecessariamente alta por estimar 16 coeficientes sem sinal real). O Modelo 1 atinge o ponto de equilíbrio ideal no trade-off viés-variância.

Exercício 3.28 — Implementando a Função `summary(X, y)` ***[Exercício de Programação]***

Estenda `ols` do Exercício 3.18 para uma função `summary(X, y)` que devolve, para cada coeficiente, $\hat{\beta}_j$, $\text{SE}(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2[(X^TX)^{-1}]_{jj}}$, estatística t_j e p-valor, além de RSE, R^2, R^2_{adj} e F.
a. Gere dados com $p = 3$ preditores ($N = 100$), dois relevantes e um irrelevante.
b, c, d. Simulação com multicolinearidade ($r = 0.99$) e verificação da estabilidade dos testes F e t.

Comentário Teórico

1. **Estrutura Algébrica da Tabela de Regressão:** A variância do estimador matricial MQO é $\text{Var}(\hat{\beta}) = \sigma^2(X^TX)^{-1}$. Ao substituir σ^2 pelo seu estimador não-viesado $\hat{\sigma}^2 = \frac{\text{RSS}}{N-p-1}$, os erros-padrão de cada coeficiente são obtidos diretamente extraindo a raiz quadrada dos elementos da diagonal principal: $\text{SE}(\hat{\beta}_j) = \hat{\sigma}\sqrt{[(X^TX)^{-1}]_{jj}}$. A estatística de teste individual é $t_j = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)}$, e o valor-$p$ bicaudal é computado via distribuição t_{N-p-1}.

2. **Comportamento Sob Multicolinearidade Severa ($r = 0.99$):** Quando dois preditores são fortemente correlacionados, as colunas correspondentes em X tornam-se quase linearmente dependentes. O determinante de X^TX aproxima-se de zero, e os elementos da diagonal de $(X^TX)^{-1}$ explodem (mecanismo conhecido como Fator de Inflação da Variância, VIF). Como resultado, $\text{SE}(\hat{\beta}_j)$ torna-se gigantesco, reduzindo drasticamente t_j e produzindo valores-$p > 0.05$ para ambas as variáveis. Não obstante, a estatística F global permanece altamente significativa, pois o espaço gerado por ambas as variáveis em conjunto captura com precisão a variância da resposta.

---

2 Regularização: Ridge (Tópico 3.5)

Exercício 3.29 — Propriedades Qualitativas do Estimador Ridge

a. Complete e justifique: "em relação a mínimos quadrados, ridge é [mais / menos] flexível e melhora a previsão quando [o aumento do viés² / a redução da variância] é maior que [o aumento do viés² / a redução da variância]".
b. Com λ crescendo a partir de zero, diga se cada quantidade aumenta sempre, diminui sempre, tem forma de U ou é constante: erro de treino, erro de teste, variância, viés², erro irredutível.
c. Tome $N = p$ e $X = I$ (sem intercepto). Mostre que a solução ridge é $\hat{\beta}_j = \frac{y_j}{1+\lambda}$. Interprete a palavra encolhimento.
d. Por que se padroniza os preditores antes de aplicar ridge? O que aconteceria com um preditor medido em uma unidade mil vezes menor?

Resolução

a. "Em relação a mínimos quadrados, ridge é **menos flexível** e melhora a previsão quando **a redução da variância** é maior que **o aumento do viés²**."
Justificativa: A penalidade L_2 impõe uma restrição sobre a norma dos coeficientes ($\|\beta\|_2^2 \leq s$), restringindo o espaço de busca efetivo das soluções e tornando a estimativa mais rígida em relação aos dados de treino.

b. Com $\lambda \geq 0$ crescendo:

- **Erro de Treino:** Aumenta sempre (pois $\lambda = 0$ minimiza a RSS sem restrições; adicionar a penalidade restringe o minimizador).
- **Erro de Teste:** Forma de U (diminui inicialmente devido à forte queda na variância, atinge um mínimo em λ^*, e volta a subir quando o viés domina).
- **Variância:** Diminui sempre (à medida que $\lambda \to \infty$, $\hat{\beta}_\lambda \to 0$ e a variabilidade amostral zera).
- **Viés²:** Aumenta sempre (o estimador é forçado a encolher em direção a zero, afastando-se do valor verdadeiro).
- **Erro Irredutível:** Constante (igual a σ^2, independente de λ).

c. Com $X = I_p$, a função objetivo de ridge é:

$$L(\beta) = \|y - \beta\|_2^2 + \lambda\|\beta\|_2^2 = \sum_{j=1}^{p} \left((y_j - \beta_j)^2 + \lambda\beta_j^2\right)$$

Derivando em relação a β_j e igualando a zero:

$$-2(y_j - \beta_j) + 2\lambda\beta_j = 0 \implies \beta_j(1+\lambda) = y_j \implies \hat{\beta}_j = \frac{y_j}{1+\lambda}$$

Interpretação: A solução MQO tradicional é $\hat{\beta}_{\text{MQ},j} = y_j$. O estimador ridge encolhe (*shrinkage*) a solução de mínimos quadrados multiplicando-a pelo fator escalar $\frac{1}{1+\lambda} < 1$. Quando $\lambda \to \infty$, $\hat{\beta}_j \to 0$.

d. A penalização ridge soma $\lambda \sum_{j=1}^{p} \beta_j^2$, que aplica o mesmo peso numérico a todos os coeficientes. Se um preditor x_j for medido em unidades $1000\times$ menores (ex.: miligramas em vez de quilogramas), seu coeficiente verdadeiro β_j precisa ser $1000\times$ maior para manter o mesmo efeito sobre Y. A penalização quadrática penalizaria β_j^2 por um fator de $1.000.000\times$ mais severo! A padronização (transformando cada preditor para ter média 0 e variância 1) garante que o encolhimento seja invariante às escalas de medição.

Exercício 3.30 — Solução Fechada e Colunas Idênticas

Considere ridge sem intercepto: $L(\beta) = (y - X\beta)^T(y - X\beta) + \lambda\beta^T\beta$.
a. Mostre que $\hat{\beta}_{\text{ridge}} = (X^TX + \lambda I)^{-1}X^Ty$ e que $X^TX + \lambda I$ é invertível para todo $\lambda > 0$, mesmo quando X^TX não é.
b. Suponha que duas colunas de X são idênticas. Mínimos quadrados tem infinitas soluções; mostre que ridge tem uma única, e que nela os dois coeficientes são iguais.

Resolução

a. Expansão da função objetivo:

$$L(\beta) = y^Ty - 2\beta^TX^Ty + \beta^TX^TX\beta + \lambda\beta^T\beta$$

Gradiente em relação a β:

$$\frac{\partial L}{\partial \beta} = -2X^Ty + 2X^TX\beta + 2\lambda\beta = 0 \implies (X^TX + \lambda I)\beta = X^Ty$$

Para provar a invertibilidade: A matriz X^TX é simétrica e semi-definida positiva, com autovalores $d_j \geq 0$. Os autovalores da matriz $M = X^TX + \lambda I$ são $d_j + \lambda$. Como $\lambda > 0$, temos $d_j + \lambda \geq \lambda > 0$. Todos os autovalores de M são estritamente positivos, garantindo que M é **definida positiva** e, portanto, **inversível para qualquer $\lambda > 0$**. Multiplicando pela inversa:

$$\hat{\beta}_{\text{ridge}} = (X^TX + \lambda I)^{-1}X^Ty$$

b. Sejam as colunas 1 e 2 de X idênticas ($X_1 = X_2 = v$).
No MQO, qualquer combinação com $\beta_1 + \beta_2 = c$ constante produz a mesma previsão $v(\beta_1 + \beta_2) = vc$, resultando em infinitas soluções.
No ridge, para uma soma fixa $s = \beta_1 + \beta_2$, a parcela de ajuste RSS é idêntica, mas a penalidade exige minimizar $\beta_1^2 + \beta_2^2$. Substituindo $\beta_2 = s - \beta_1$:

$$g(\beta_1) = \beta_1^2 + (s - \beta_1)^2 \implies g'(\beta_1) = 2\beta_1 - 2(s - \beta_1) = 0 \implies 2\beta_1 = s \implies \beta_1 = \beta_2 = \frac{s}{2}$$

Como a função objetivo é estritamente convexa para $\lambda > 0$, a solução é **única** e obriga que os coeficientes de colunas idênticas sejam estritamente iguais: $\hat{\beta}_1 = \hat{\beta}_2$.

Exercício 3.31 — Propriedades Avançadas do Estimador Ridge (Desafio)

a. Dados Aumentados: Mostre que $\hat{\beta}_\lambda$ é a solução de MQO para a matriz aumentada $\tilde{X} = \begin{pmatrix} X \\ \sqrt{\lambda} I_p \end{pmatrix}$ e resposta aumentada $\tilde{y} = \begin{pmatrix} y \\ 0_p \end{pmatrix}$.

b. Colunas Ortonormais: Se $X^T X = I$, mostre que $\hat{\beta}_\lambda = \frac{\hat{\beta}_{\text{MQ}}}{1+\lambda}$.

c. Viés: Sob $\mathbb{E}[\epsilon] = 0$, mostre que $\mathbb{E}[\hat{\beta}_\lambda] = (X^T X + \lambda I)^{-1} X^T X \beta$. Conclua que é viesado para $\lambda > 0$ e determine $\lim_{\lambda \to \infty} \mathbb{E}[\hat{\beta}_\lambda]$.

d. Variância: Mostre que $\text{Var}(\hat{\beta}_\lambda) = \sigma^2 (X^T X + \lambda I)^{-1} X^T X (X^T X + \lambda I)^{-1}$. Diagonalize $X^T X = Q \Lambda Q^T$ e analise os autovalores.

e. Monotonicidade: Mostre que $\lambda \mapsto \|\hat{\beta}_\lambda\|_2$ é não-crescente e $\lambda \mapsto \text{RSS}(\hat{\beta}_\lambda)$ é não-decrescente.

Resolução

a. Calculando as matrizes de produto para os dados aumentados:

$$\tilde{X}^T \tilde{X} = \begin{pmatrix} X^T & \sqrt{\lambda} I_p \end{pmatrix} \begin{pmatrix} X \\ \sqrt{\lambda} I_p \end{pmatrix} = X^T X + \lambda I_p$$

$$\tilde{X}^T \tilde{y} = \begin{pmatrix} X^T & \sqrt{\lambda} I_p \end{pmatrix} \begin{pmatrix} y \\ 0_p \end{pmatrix} = X^T y$$

Portanto, a solução de MQO no sistema aumentado é:

$$\hat{\beta}_{\text{MQO}}(\tilde{X}, \tilde{y}) = (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{y} = (X^T X + \lambda I_p)^{-1} X^T y = \hat{\beta}_\lambda$$

b. Se $X^T X = I$:

$$\hat{\beta}_\lambda = (I + \lambda I)^{-1} X^T y = \frac{1}{1+\lambda} X^T y$$

Como $\hat{\beta}_{\text{MQ}} = (X^T X)^{-1} X^T y = X^T y$, conclui-se diretamente que $\hat{\beta}_\lambda = \frac{\hat{\beta}_{\text{MQ}}}{1+\lambda}$.

c. Com $y = X\beta + \epsilon$ e $\mathbb{E}[\epsilon] = 0$:

$$\mathbb{E}[\hat{\beta}_\lambda] = \mathbb{E}\Big[(X^T X + \lambda I)^{-1} X^T (X\beta + \epsilon)\Big] = (X^T X + \lambda I)^{-1} X^T X \beta$$

Para qualquer $\lambda > 0$, como $(X^T X + \lambda I)^{-1} X^T X \neq I$, temos $\mathbb{E}[\hat{\beta}_\lambda] \neq \beta$ (estimador viesado). Quando $\lambda \to \infty$, a matriz inversa aproxima-se de zero, logo $\lim_{\lambda \to \infty} \mathbb{E}[\hat{\beta}_\lambda] = 0$.

d. Como $\text{Var}(y) = \sigma^2 I$ e $\hat{\beta}_\lambda = M X^T y$ com $M = (X^T X + \lambda I)^{-1}$:

$$\text{Var}(\hat{\beta}_\lambda) = M X^T \text{Var}(y) (M X^T)^T = \sigma^2 M X^T X M = \sigma^2 (X^T X + \lambda I)^{-1} X^T X (X^T X + \lambda I)^{-1}$$

Diagonalizando $X^T X = Q \Lambda Q^T$ onde $\Lambda = \text{diag}(d_1, \ldots, d_p)$:

$$\text{Var}(\hat{\beta}_\lambda) = \sigma^2 Q \text{diag}\left(\frac{d_j}{(d_j + \lambda)^2} \right) Q^T$$

Os autovalores da variância na direção j são $\frac{\sigma^2 d_j}{(d_j+\lambda)^2}$. No MQO ($\lambda = 0$), direções colineares com $d_j \approx 0$ causam a explosão da variância ($\sigma^2/d_j \to \infty$). No ridge ($\lambda > 0$), a variância é limitada por $\frac{\sigma^2 d_j}{\lambda^2} \approx 0$, contendo a variabilidade.

e. Prova de Monotonicidade: Sejam $\lambda_1 < \lambda_2$, e as correspondentes soluções $\beta_1 = \hat{\beta}_{\lambda_1}$ e $\beta_2 = \hat{\beta}_{\lambda_2}$. Pela propriedade de minimizador:

$$(1) \quad \text{RSS}(\beta_1) + \lambda_1\|\beta_1\|^2 \leq \text{RSS}(\beta_2) + \lambda_1\|\beta_2\|^2$$

$$(2) \quad \text{RSS}(\beta_2) + \lambda_2\|\beta_2\|^2 \leq \text{RSS}(\beta_1) + \lambda_2\|\beta_1\|^2$$

Somando ambas as desigualdades e cancelando $\text{RSS}(\beta_1) + \text{RSS}(\beta_2)$:

$$\lambda_1\|\beta_1\|^2 + \lambda_2\|\beta_2\|^2 \leq \lambda_1\|\beta_2\|^2 + \lambda_2\|\beta_1\|^2 \implies (\lambda_2 - \lambda_1)\|\beta_2\|^2 \leq (\lambda_2 - \lambda_1)\|\beta_1\|^2$$

Como $\lambda_2 - \lambda_1 > 0$, conclui-se que $\|\beta_2\|^2 \leq \|\beta_1\|^2$, ou seja, $\lambda \mapsto \|\hat{\beta}_\lambda\|_2$ é **não-crescente**. Utilizando $\|\beta_2\|^2 \leq \|\beta_1\|^2$ na desigualdade (1):

$$\text{RSS}(\beta_2) - \text{RSS}(\beta_1) \geq \lambda_1(\|\beta_1\|^2 - \|\beta_2\|^2) \geq 0 \implies \text{RSS}(\beta_2) \geq \text{RSS}(\beta_1)$$

Logo, $\lambda \mapsto \text{RSS}(\hat{\beta}_\lambda)$ é **não-decrescente**.

Exercício 3.32 — Implementando o Estimador Ridge *[Exercício de Programação]*

Implemente `ridge(X, y, lam)` pela solução fechada sem penalizar o intercepto.
a. Implementação com centralização de variáveis.
b, c. Simulação com preditores correlacionados ($p = 5, N = 40$), escolha de λ por k-fold CV e comparação com o erro de teste mínimo.

Comentário Teórico

1. **Centralização e Intercepto:** Ao aplicar o encolhimento ridge, o intercepto β_0 não deve ser penalizado, pois ele apenas define o nível médio da resposta Y. A estratégia padrão consiste em centralizar Y e todas as colunas de X subtraindo suas respectivas médias: $\tilde{y}_i = y_i - \bar{y}$ e $\tilde{x}_{ij} = x_{ij} - \bar{x}_j$. A solução para o intercepto é dada diretamente por $\hat{\beta}_0 = \bar{y}$, enquanto a solução matricial $\hat{\beta}_{\text{ridge}} = (\tilde{X}^T\tilde{X} + \lambda I)^{-1}\tilde{X}^T\tilde{y}$ é aplicada estritamente sobre os coeficientes das variáveis inclinadas.

2. **Validação Cruzada para λ:** A curva do erro quadrático médio de teste obtida por validação cruzada k-fold apresenta um formato convexo característico em U. O valor ótimo λ^* que minimiza a estimativa do erro de generalização compensa de forma perfeita o aumento de viés quadrático pelo ganho em estabilidade (redução substancial de variância) decorrente da regularização.

---

3 Além de Aproximações Lineares (Tópico 3.6)

Exercício 3.33 — Interação e Linearidade nos Parâmetros

Considere o modelo: $\hat{\text{As}} = \beta_0 + \beta_1\text{pH} + \beta_2\text{turb} + \beta_3(\text{pH} \cdot \text{turb})$.
a. O que β_1 mede quando $\beta_3 = 0$? Escreva o efeito de aumentar o pH em uma unidade como função da turbidez.
b. Para quais valores de turbidez o efeito do pH é positivo?
c. "$\hat{\beta}_3$ é pequeno, logo a interação não importa." Critique, pensando na escala das variáveis.
d. Para cada modelo, diga se é linear nos parâmetros e escreva a matriz design: (1) $\beta_0 + \beta_1 x_1 + \beta_2 x_1^2$, (2) $\beta_0 + \beta_1 \log x_1$, (3) $e^{\beta_0 + \beta_1 x_1}$, (4) $\beta_0 + \beta_1 x_1 x_2$.
e. Regressão polinomial de grau d é regressão linear. Por que ela sobreajusta quando d cresce?

Resolução

a. Quando $\beta_3 = 0$, β_1 representa o efeito aditivo direto e marginal do pH na concentração de arsênio, constante para qualquer nível de turbidez. Na presença do termo de interação ($\beta_3 \neq 0$), o efeito parcial de aumentar o pH em uma unidade é obtido derivando o modelo em relação ao pH:

$$\frac{\partial \hat{\text{As}}}{\partial \text{pH}} = \beta_1 + \beta_3 \text{turb}$$

O efeito marginal do pH é uma função linear dependente da turbidez.

b. O efeito do pH é positivo quando $\frac{\partial \hat{\text{As}}}{\partial \text{pH}} > 0 \iff \beta_1 + \beta_3 \text{turb} > 0$:

- Se $\beta_3 > 0$: $\text{turb} > -\frac{\beta_1}{\beta_3}$.
- Se $\beta_3 < 0$: $\text{turb} < -\frac{\beta_1}{\beta_3}$.

c. Afirmação incorreta. A escala do coeficiente $\hat{\beta}_3$ depende das unidades de medida das variáveis originais. Se a turbidez for dada em uma escala com valores elevados (ex.: centenas de NTU), o produto pH·turb assume magnitudes numéricas grandes, exigindo um coeficiente $\hat{\beta}_3$ pequeno para gerar uma alteração relevante em $\hat{\text{As}}$. A importância da interação deve ser avaliada pela estatística t, pelo teste F ou pelo impacto preditivo, e não pela ordem de grandeza absoluta do coeficiente.

d. Classificação quanto à linearidade nos parâmetros:

(a) $\beta_0 + \beta_1 x_1 + \beta_2 x_1^2$: **Linear nos parâmetros**. Matriz design com colunas $[1, x_1, x_1^2]$.

(b) $\beta_0 + \beta_1 \log x_1$: **Linear nos parâmetros**. Matriz design com colunas $[1, \log x_1]$.

(c) $e^{\beta_0 + \beta_1 x_1}$: **Não-linear nos parâmetros** (parâmetros figuram no expoente; não pode ser rearranjado como $X\beta$).

(d) $\beta_0 + \beta_1 x_1 x_2$: **Linear nos parâmetros**. Matriz design com colunas $[1, x_1 x_2]$.

e. Embora a regressão polinomial seja um modelo linear sob o ponto de vista da álgebra matricial ($Y = X\beta + \epsilon$), a flexibilidade funcional da classe $\mathcal{G}_d$ cresce com o grau d. Polinômios de grau alto possuem alta capacidade de curvatura, permitindo oscilações de alta frequência entre os pontos de amostragem (Fenômeno de Runge nas bordas), o que eleva a variância do estimador e provoca sobreajuste.

Exercício 3.34 — Propriedades da Regressão Polinomial

Seja $\text{RSS}(d)$ a soma dos quadrados dos resíduos do ajuste polinomial de grau d a N pontos com x_i distintos.
a. Mostre que $\text{RSS}(d)$ é não-crescente em d e que $\text{RSS}(N-1) = 0$.
b. Mostre que se os x_i são simétricos em torno de 0, as colunas de potências pares e ímpares na matriz design são ortogonais. O que isso implica para $\hat{\beta}_1$ ao passar do grau 1 para 2 e 3?
c. Por que a matriz X com $[1, x, x^2, \ldots, x^d]$ em $x_i \in [0, 1]$ tem $X^T X$ quase singular quando d cresce? O que centrar os x_i resolve e não resolve?

Resolução

a. O espaço gerado pela base de grau d, $\mathcal{G}_d = \text{span}(1, x, \ldots, x^d)$, é um subespaço de $\mathcal{G}_{d+1} = \text{span}(1, x, \ldots, x^d, x^{d+1})$. Pela propriedade das projeções ortogonais (Exercício 3.13), projetar sobre um espaço maior nunca aumenta a distância residual. Logo, $\text{RSS}(d+1) \leq \text{RSS}(d)$, provando que $\text{RSS}(d)$ é não-crescente em d.

Para $d = N-1$, o espaço das colunas possui dimensão N (pois a matriz de Vandermonde para N pontos distintos é invertível, Exercício 2.3). O polinômio interpola exatamente todos os N pontos, resultando em resíduos nulos: $\text{RSS}(N-1) = 0$.

b. O produto interno entre a coluna da potência k e da potência m é $\langle x^k, x^m \rangle = \sum_{i=1}^{N} x_i^{k+m}$. Se o conjunto de pontos é simétrico em torno de zero, para cada ponto x_i existe o correspondente $-x_i$.
Se uma potência for par (k) e a outra ímpar (m), a soma $k+m$ é ímpar. Assim:

$$\sum_{i=1}^{N} x_i^{k+m} = \sum_{x_i>0} \left(x_i^{k+m} + (-x_i)^{k+m} \right) = \sum_{x_i>0} \left(x_i^{k+m} - x_i^{k+m} \right) = 0$$

Todas as colunas de potências pares são ortogonais a todas as colunas de potências ímpares.
Implicações para $\hat{\beta}_1$:

- Passar de $d = 1$ para $d = 2$: adiciona-se x^2 (par). Como $x^2 \perp x^1$, pela propriedade de projeções ortogonais (Teorema de Frisch-Waugh-Love), a estimativa de $\hat{\beta}_1$ **não se altera**.
- Passar de $d = 2$ para $d = 3$: adiciona-se x^3 (ímpar). Como x^3 não é ortogonal a x^1, a inclusão de x^3 **altera** a estimativa de $\hat{\beta}_1$.

c. No intervalo $x_i \in [0, 1]$, as funções de base x^k e x^{k+1} tornam-se quase idênticas para k elevado (ex.: as curvas de x^8 e x^9 são quase indistinguíveis no intervalo). As colunas da matriz design X tornam-se fortemente correlacionadas, fazendo com que $X^T X$ aproxima-se da matriz de Hilbert, que é notoriamente quase singular e mal-condicionada.
Efeito: A variância dos coeficientes individuais $\text{Var}(\hat{\beta}_j) = \sigma^2 [(X^T X)^{-1}]_{jj}$ explode.
Centração: Subtrair a média $(x_i - \bar{x})$ elimina a correlação entre potências de paridades distintas (par vs ímpar), ortogonalizando-as no caso simétrico. No entanto, **não resolve** a colinearidade estrutural entre potências da mesma paridade (ex.: entre $(x-\bar{x})^2$ e $(x-\bar{x})^4$), exigindo o uso de polinômios ortogonais (Legendre/Chebyshev) ou regularização ridge.

Exercício 3.35 — Fechando o Ciclo: Polinômios e Regularização ***[Exercício de Programação]***

Escreva `poly_design(x, d)` que monta a matriz design e use `ols` e `ridge` para ajustar polinômios.
a, b, c. Simulação do trade-off viés-variância no ajuste polinomial de grau d e comparação entre o polinômio de grau ótimo sem regularização e o polinômio de grau alto regularizado com ridge.

Comentário Teórico

1. **Síntese de Flexibilidade e Regularização:** O estudo dirigido encerra-se demonstrando a poderosa relação de complementaridade entre a capacidade de representação funcional e a regularização de parâmetros. Ajustar um polinômio de grau reduzido (ex.: $d = 2$) sem regularização pode introduzir viés de especificação caso a verdadeira função subjacente $f(x)$ possua oscilações mais complexas. Por outro lado, aumentar o grau d sem restrições dispara a variância.

2. **Vantagem do Polinômio de Grau Alto Regularizado por Ridge:** Ao utilizar uma base polinomial rica e de grau elevado (ex.: $d = 10$) combinada com a penalidade ridge ($\lambda > 0$), obtém-se o melhor dos dois mundos. A riqueza da base reduz o viés ao mínimo necessário para

capturar padrões complexos, enquanto a penalidade L_2 encolhe suavemente os coeficientes associados às potências de alta ordem, eliminando oscilações parasitas e controlando eficazmente a variância de generalização.