Aprendizado de Máquina I (MD22)

Soluções das Questões: Tópico 3 — Regressão Linear

IMPA Tech | Período 2026.2 | Autor do Estudo Dirigido: Rodrigo Ribeiro

Nota de Apresentação: Este documento contém a resolução completa e fundamentada dos exercícios do Capítulo 3 (*Regressão Linear*), abrangendo as Seções 3.1, 3.2 e 3.3 (páginas 21 em diante), conforme requisitado. Para cada exercício, é apresentado o **enunciado integral** seguido da respectiva demonstração ou solução analítica. Para os exercícios de **Programação**, conforme instrução expressa, apresenta-se o enunciado acompanhado exclusivamente do devido **comentário teórico**.

Contents

1 Mínimos Quadrados, Caso $p = 1$ 1

2 Caso Geral 5

3 Acurácia dos Coeficientes 10

1 Mínimos Quadrados, Caso $p = 1$

Exercício 3.1 [Conceitual]

Enunciado:

a. RSS e MSE diferem por um fator N. Qual das duas serve para comparar ajustes em conjuntos de tamanhos diferentes? Qual aparece naturalmente na verossimilhança?

b. Por que mínimos quadrados soma distâncias verticais e não perpendiculares à reta? Relacione com o que é aleatório no modelo $Y = \beta_0 + \beta_1 X + \varepsilon$.

c. Em $\hat{\beta}_1 = \mathrm{Cov}(x, y)/\mathrm{Var}(x)$, quais as unidades de $\hat{\beta}_1$? Se $\hat{\beta}_1 = 0$, Y é independente de X? Dê um contraexemplo.

d. O vetor de resíduos $r = y - \hat{y}$ é ortogonal ao vetor de uns e ao vetor x. Traduza cada ortogonalidade em uma frase sobre o ajuste.

Solução:

a. O **MSE** ($\text{MSE} = \frac{1}{N}\text{RSS}$) serve para comparar ajustes em conjuntos de tamanhos N diferentes, pois normaliza o erro pela quantidade de observações. A **RSS** ($\text{RSS} = \sum_{i=1}^{N}(y_i - \hat{y}_i)^2$) surge naturalmente na função de verossimilhança sob ruído gaussiano $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, onde a log-verossimilhança condicional é proporcional a $-\frac{1}{2\sigma^2}\text{RSS}$.

b. No modelo $Y = \beta_0 + \beta_1 X + \varepsilon$, a variável explicativa X é tratada como determinística/fixa, enquanto Y é a única variável aleatória. O objetivo é prever a variabilidade em Y dado X. Somar distâncias perpendiculares (regressão Ortogonal) assumiria erro de medição simétrico em X e Y, o que não condiz com a formulação do aprendizado supervisionado de minimizar o erro de previsão em Y.

c. A unidade de $\hat{\beta}_1$ é $\frac{\text{unidade de } Y}{\text{unidade de } X}$. Ter $\hat{\beta}_1 = 0$ indica ausência de associação **linear**, mas não implica independência estocástica. *Contraexemplo:* Seja $X \sim \text{Unif}[-1, 1]$ e $Y = X^2$. X e Y são completamente dependentes, mas $\text{Cov}(X, Y) = E[X^3] - E[X]E[X^2] = 0$, resultando em $\hat{\beta}_1 = 0$.

d.
- $r \perp \mathbf{1} \iff \sum_{i=1}^{N} r_i = 0$: A soma (e média) dos resíduos no modelo com intercepto é nula; a média das previsões é igual à média das respostas observadas ($\bar{\hat{y}} = \bar{y}$).
- $r \perp x \iff \sum_{i=1}^{N} x_i r_i = 0$: Não há correlação linear entre os resíduos e a variável preditora x; o modelo extraiu toda a tendência linear presente em x.

Exercício 3.2 [Conceitual — Linear ou Cúbico?]

Enunciado: Suponha que a relação verdadeira seja $Y = \beta_0 + \beta_1 X + \varepsilon$ e que ajustemos, aos mesmos dados, uma reta e um polinômio cúbico.

a. Qual dos dois tem menor RSS de treino, ou não é possível dizer? Justifique.

b. E RSS de teste?

c. Repita (a) e (b) supondo que a relação verdadeira é não-linear, mas não sabemos o quanto.

Solução:

a. O **polinômio cúbico** terá menor ou igual RSS de treino ($\text{RSS}_{\text{cúbico}} \leq \text{RSS}_{\text{reta}}$). Como a classe das retas é um subconjunto aninhado na classe dos polinômios de grau 3, a otimização por mínimos quadrados no espaço maior alcança um resíduo no mínimo igual ou inferior ao ajustar o ruído da amostra.

b. A **reta** terá menor RSS de teste esperada. Como o processo gerador de dados é genuinamente linear, a reta possui viés nulo e menor variância (ajusta 2 parâmetros contra 4 do cúbico). O cúbico sofre de sobreajuste (*overfitting*), capturando ruído aleatório.

c.
- *RSS de treino:* O polinômio cúbico mantém RSS de treino menor ou igual, pelo mesmo argumento de modelos aninhados.
- *RSS de teste:* Não é possível afiançar categoricamente. Se a não-linearidade for acentuada, o viés da reta dominará e o cúbico terá menor RSS de teste. Se a não-linearidade for sutil ou o tamanho amostral N for reduzido, a reta pode ter menor erro de teste devido à menor variância.

Exercício 3.3 [Prático — Com Intercepto, à Mão]

Enunciado: Para os dados do Exercício 2.9 (Tabela 2.1: $X = \{1, 2, 3, 4\}$, $Y = \{3, 4, 8, 10\}$), ajuste $Y = \beta_0 + \beta_1 X + \varepsilon$: calcule $\hat{\beta}_0$, $\hat{\beta}_1$ e a RSS. Compare com a RSS do ajuste sem intercepto. Por que a RSS não pode ter aumentado?

Solução: Dados: $N = 4$; $x = (1, 2, 3, 4)^T$, $y = (3, 4, 8, 10)^T$.

- Médias: $\bar{x} = \frac{1+2+3+4}{4} = 2.5$, $\bar{y} = \frac{3+4+8+10}{4} = 6.25$.
- Desvios: $x - \bar{x} = (-1.5, -0.5, 0.5, 1.5)^T$, $y - \bar{y} = (-3.25, -2.25, 1.75, 3.75)^T$.
- $\sum (x_i - \bar{x})^2 = (-1.5)^2 + (-0.5)^2 + 0.5^2 + 1.5^2 = 2.25 + 0.25 + 0.25 + 2.25 = 5.0$.
- $\sum (x_i - \bar{x})(y_i - \bar{y}) = (-1.5)(-3.25) + (-0.5)(-2.25) + 0.5(1.75) + 1.5(3.75) = 4.875 + 1.125 + 0.875 + 5.625 = 12.5$.
- Coeficientes:
$$\hat{\beta}_1 = \frac{12.5}{5.0} = 2.5, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6.25 - 2.5(2.5) = 0.0$$
- Previsões $\hat{y} = (2.5, 5.0, 7.5, 10.0)^T$; Resíduos $r = y - \hat{y} = (0.5, -1.0, 0.5, 0.0)^T$.
- $\text{RSS}_{\text{com intercepto}} = 0.5^2 + (-1.0)^2 + 0.5^2 + 0^2 = 1.5$.
- No ajuste sem intercepto (Exercício 2.9): $\hat{\beta} = \frac{\sum x_i y_i}{\sum x_i^2} = \frac{75}{30} = 2.5 \implies \text{RSS}_{\text{sem intercepto}} = 1.5$.

Como $\hat{\beta}_0 = 0$ no modelo irrestrito, os dois ajustes coincidem nesta amostra. A RSS do modelo com intercepto não pode exceder a do modelo sem intercepto porque a classe com intercepto inclui a hipérbole/reta restrita $\beta_0 = 0$ como caso particular.

Exercício 3.4 [Prático]

Enunciado:

a. Reamostre várias vezes com $N = 10$ e depois com $N = 120$. O que acontece com a dispersão de $\hat{\beta}_1$? Qual termo da decomposição viés-variância isso ilustra?

b. Acrescente um ponto no centro da nuvem e arraste-o verticalmente; depois faça o mesmo com um ponto na borda. Qual altera mais a reta? Explique com os pesos w_i na fórmula de $\hat{\beta}_1$.

Solução:

a. Aumentando de $N = 10$ para $N = 120$, a dispersão (variância) das estimativas $\hat{\beta}_1$ reduz-se drasticamente ao redor do valor verdadeiro β_1. Isso ilustra a redução da **variância da estimativa**, visto que $\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2} \propto \frac{1}{N}$.

b. O ponto na **borda** altera muito mais a inclinação da reta. Pela fórmula $\hat{\beta}_1 = \sum w_i y_i$, onde $w_i = \frac{x_i - \bar{x}}{\sum (x_j - \bar{x})^2}$, pontos distantes da média $\bar{x}$ possuem desvios $|x_i - \bar{x}|$ elevados, resultando em pesos $|w_i|$ superiores (alta alavancagem ou *leverage*).

Exercício 3.5 [Demonstração]

Enunciado:

a. Derive as equações normais para $\text{RSS}(\beta_0, \beta_1)$ e resolva-as, obtendo $\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$ e $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$.

b. Conclua que a reta ajustada passa por $(\bar{x}, \bar{y})$ e que os resíduos satisfazem $\sum r_i = 0$ e $\sum x_i r_i = 0$.

c. No ajuste sem intercepto, mostre que $\hat{y}_i = \sum a_{ii'} y_{i'}$ e encontre os $a_{ii'}$. Em que sentido "a previsão é uma combinação linear dos y"? Que $y_{i'}$ pesam mais?

Solução:

a. $\text{RSS}(\beta_0, \beta_1) = \sum_{i=1}^{N}(y_i - \beta_0 - \beta_1 x_i)^2$.

$$\frac{\partial \text{RSS}}{\partial \beta_0} = -2\sum_{i=1}^{N}(y_i - \beta_0 - \beta_1 x_i) = 0 \implies \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\frac{\partial \text{RSS}}{\partial \beta_1} = -2\sum_{i=1}^{N} x_i(y_i - \beta_0 - \beta_1 x_i) = 0 \implies \sum x_i(y_i - \bar{y}) = \hat{\beta}_1 \sum x_i(x_i - \bar{x})$$

Como $\sum x_i(y_i - \bar{y}) = \sum(x_i - \bar{x})(y_i - \bar{y})$ e $\sum x_i(x_i - \bar{x}) = \sum(x_i - \bar{x})^2$, obtém-se $\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$.

b. $\hat{y}(\bar{x}) = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} = (\bar{y} - \hat{\beta}_1 \bar{x}) + \hat{\beta}_1 \bar{x} = \bar{y}$. Logo, passa por $(\bar{x}, \bar{y})$. Das condições de 1ª ordem: $\frac{\partial \text{RSS}}{\partial \beta_0} = 0 \implies \sum r_i = 0$, e $\frac{\partial \text{RSS}}{\partial \beta_1} = 0 \implies \sum x_i r_i = 0$.

c. Sem intercepto, $\hat{\beta} = \frac{\sum x_{i'} y_{i'}}{\sum x_k^2}$. Assim, $\hat{y}_i = x_i \hat{\beta} = \sum_{i'=1}^{N} \left(\frac{x_i x_{i'}}{\sum_{k=1}^{N} x_k^2} \right) y_{i'}$. Logo $a_{ii'} = \frac{x_i x_{i'}}{\sum_k x_k^2}$. As previsões são combinações lineares dos $y_{i'}$ observados. Os pontos $y_{i'}$ com preditores $x_{i'}$ de mesma direção e grande magnitude em relação a x_i possuem maior peso.

Exercício 3.6 [Demonstração — O Ponto Crítico é Mínimo]

Enunciado: Mostre que a Hessiana de $\text{RSS}(\beta_0, \beta_1)$ é definida positiva se, e somente se, existem i, j com $x_i \neq x_j$. O que acontece com $\hat{\beta}$ quando todos os x_i são iguais? Interprete geometricamente.

Solução: A matriz Hessiana é dada por:

$$H = 2 \begin{bmatrix} N & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix}$$

Como $2N > 0$, H é definida positiva se e somente se o determinante for estritamente positivo:

$$\det(H) = 4\left(N \sum x_i^2 - (\sum x_i)^2\right) = 4N \sum_{i=1}^{N}(x_i - \bar{x})^2 > 0 \iff \exists i, j \text{ tal que } x_i \neq x_j$$

Se todos $x_i = c$, a variância dos preditores é nula ($\sum(x_i - \bar{x})^2 = 0$), tornando $\det(H) = 0$. O denominador de $\hat{\beta}_1$ anula-se e existem infinitas retas minimizando a RSS. Geometricamente, as observações situam-se sobre uma única reta vertical $x = c$ em $\mathbb{R}^2$, impedindo a identificação da inclinação.

Exercício 3.7 [Demonstração — Média e Variância de $\hat{\beta}_1$]

Enunciado: Suponha $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ com x_i fixos e ε_i independentes ($\mu = 0, \sigma^2$).

a. Mostre que $\hat{\beta}_1 = \sum w_i y_i$ com $w_i = (x_i - \bar{x}) / \sum(x_j - \bar{x})^2$. Onde se usa $\sum w_i = 0$?

b. Mostre que $E[\hat{\beta}_1] = \beta_1$ e $\text{Var}(\hat{\beta}_1) = \sigma^2 / \sum(x_i - \bar{x})^2$. Interprete a variância com N e dispersão de x.

c. Mostre que $E[\hat{\beta}_0] = \beta_0$ e $\text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{N} + \frac{\bar{x}^2}{\sum(x_i - \bar{x})^2} \right)$. Por que centrar os x_i torna $\hat{\beta}_0$ mais preciso?

Solução:

a. $\sum(x_i-\bar{x})\bar{y}=0 \implies \sum(x_i-\bar{x})(y_i-\bar{y})=\sum(x_i-\bar{x})y_i$. Definindo $w_i=\frac{x_i-\bar{x}}{\sum(x_j-\bar{x})^2}$, temos $\hat{\beta}_1=\sum w_i y_i$. Nota-se que $\sum w_i=\frac{\sum(x_i-\bar{x})}{\sum(x_j-\bar{x})^2}=0$.

b. $E[\hat{\beta}_1]=\sum w_i E[y_i]=\sum w_i(\beta_0+\beta_1 x_i)=\beta_0\sum w_i+\beta_1\sum w_i x_i$. Usou-se $\sum w_i=0$ para anular o termo em β_0. Como $\sum w_i x_i=1$, $E[\hat{\beta}_1]=\beta_1$.

$$\mathrm{Var}(\hat{\beta}_1)=\sum w_i^2\mathrm{Var}(y_i)=\sigma^2\sum\frac{(x_i-\bar{x})^2}{(\sum(x_j-\bar{x})^2)^2}=\frac{\sigma^2}{\sum(x_i-\bar{x})^2}$$

Quando N cresce ou os x_i são mais dispersos, o denominador aumenta e a variância diminui.

c. $E[\hat{\beta}_0]=E[\bar{y}]-\bar{x}E[\hat{\beta}_1]=(\beta_0+\beta_1\bar{x})-\bar{x}\beta_1=\beta_0$. Escrevendo $\hat{\beta}_0=\sum\left(\frac{1}{N}-\bar{x}w_i\right)y_i$:

$$\mathrm{Var}(\hat{\beta}_0)=\sigma^2\sum\left(\frac{1}{N^2}-\frac{2\bar{x}w_i}{N}+\bar{x}^2w_i^2\right)=\sigma^2\left(\frac{1}{N}+\frac{\bar{x}^2}{\sum(x_i-\bar{x})^2}\right)$$

Centrar os preditores ($\bar{x}=0$) elimina o segundo termo, minimizando a variância de $\hat{\beta}_0$ para $\frac{\sigma^2}{N}$.

2 Caso Geral

Exercício 3.8 [Demonstração — TSS, RSS, R^2]

Enunciado:

a. Usando as identidades do Ex. 3.5(b), mostre que $\text{TSS} = \sum(\hat{y}_i - \bar{y})^2 + \text{RSS}$. Interprete em $\mathbb{R}^N$.

b. Conclua que $0 \leq R^2 \leq 1$ e mostre que, para $p = 1$, $R^2 = \text{Cor}(x, y)^2$.

c. Padronize x e y ($\mu = 0, \sigma^2 = 1$). Mostre que $\hat{\beta}_0 = 0$ e $\hat{\beta}_1 = \text{Cor}(x, y)$. Justifique o nome "regressão à média".

Solução:

a. $\text{TSS} = \sum(y_i - \bar{y})^2 = \sum[(\hat{y}_i - \bar{y}) + r_i]^2 = \sum(\hat{y}_i - \bar{y})^2 + \sum r_i^2 + 2\sum(\hat{y}_i - \bar{y})r_i$. Como $\sum(\hat{y}_i - \bar{y})r_i = \hat{\beta}_0 \sum r_i + \hat{\beta}_1 \sum x_i r_i - \bar{y} \sum r_i = 0$, temos $\text{TSS} = \text{ESS} + \text{RSS}$. *Geometria:* No triângulo retângulo em $\mathbb{R}^N$, o vetor $y - \bar{y}\mathbf{1}$ é a hipotenusa, decomposto nos catetos ortogonais $\hat{y} - \bar{y}\mathbf{1}$ (projeção) e r (resíduo). Pelo Teorema de Pitágoras: $\|y - \bar{y}\mathbf{1}\|^2 = \|\hat{y} - \bar{y}\mathbf{1}\|^2 + \|r\|^2$.

b. $R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}$. Como $\text{ESS} \geq 0$ e $\text{RSS} \geq 0$, $0 \leq R^2 \leq 1$. Para $p = 1$, $\text{ESS} = \hat{\beta}_1^2 \sum(x_i - \bar{x})^2 \implies R^2 = \frac{\text{Cov}(x,y)^2}{\text{Var}(x)\text{Var}(y)} = \text{Cor}(x, y)^2$.

c. Com variáveis padronizadas, $\hat{\beta}_1 = \frac{\text{Cov}(x,y)}{\text{Var}(x)} = \text{Cor}(x, y)$ e $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 0$. Regredindo x sobre y, obtém-se $\hat{\gamma}_1 = \text{Cor}(x, y)$. Como $|\text{Cor}(x, y)| \leq 1$, o valor previsto $\hat{y}$ fica sempre mais próximo da média do que a observação x, justificando o termo "regressão à média".

Exercício 3.9 [Programação — Implementando $p = 1$]

Enunciado: Implemente `ols_p1(x, y)` devolvendo $(\hat{\beta}_0, \hat{\beta}_1)$ pelas fórmulas fechadas. Em dados sintéticos, verifique numericamente as três identidades do Exercício 3.5(b).

Comentário Teórico: *[Questão Computacional — apenas enunciado e comentário teórico]* Esta questão envolve a codificação direta dos estimadores dos mínimos quadrados ordinários unidimensionais $\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$ e $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Em seguida, realiza-se a validação computacional das três propriedades fundamentais: (1) a passagem da reta pelo centroide $(\bar{x}, \bar{y})$; (2) a ortogonalidade entre resíduos e o vetor unitário ($\sum r_i = 0$); e (3) a ortogonalidade entre resíduos e os preditores ($\sum x_i r_i = 0$).

Exercício 3.10 [Conceitual]

Enunciado:

a. Mostre que $X^T X$ é invertível se, e somente se, as colunas de X são linearmente independentes.

b. Traduza a condição em termos dos preditores.

c. Dê um exemplo com $p = 2$ em que uma coluna é múltipla da outra. Quantas soluções o problema tem? O ajuste $\hat{y} = X\hat{\beta}$ é único?

d. Explique por que (c) é um problema para inferência, mas não necessariamente para previsão.

e. Se $N < p + 1$, o que acontece com $X^T X$ e com a RSS mínima? Relacione com o Exercício 2.2.

Solução:

a. $v^T(X^TX)v = \|Xv\|^2 \implies X^TXv = 0 \iff Xv = 0$. Logo $\text{Null}(X^TX) = \text{Null}(X)$. Assim, X^TX é invertível $\iff \text{Null}(X) = \{0\} \iff$ colunas de X são L.I.

b. Não pode haver multicolinearidade perfeita: nenhum preditor (incluindo o intercepto) pode ser combinação linear exata dos demais.

c. Se $X_2 = 2X_1$, há infinitas soluções para $\hat{\beta}$ (qualquer vetor com $\hat{\beta}_1 + 2\hat{\beta}_2 = c$). No entanto, a projeção $\hat{y} = X\hat{\beta}$ no espaço $\text{col}(X)$ é única.

d. Para inferência, é impossível isolar a contribuição individual de cada preditor. Para previsão, desde que o padrão de colinearidade se mantenha no futuro, a estimativa do valor esperado $\hat{y}$ permanece válida.

e. Se $N < p+1$, $\text{posto}(X) \leq N < p+1$, tornando X^TX singular. O modelo tem parâmetros suficientes para interpolar todos os dados, atingindo $\text{RSS}_{\text{mínima}} = 0$, análogo ao interpolador do Exercício 2.2 (risco empírico zero, mas alta variância).

Exercício 3.11 [Demonstração — Cálculo Matricial e Equações Normais]

Enunciado:

a. Mostre que $\frac{\partial(v^Tx)}{\partial x} = v$ e $\frac{\partial(x^TAx)}{\partial x} = 2Ax$ para A simétrica.

b. Deduza as equações normais $X^TX\beta = X^Ty$ e mostre que $2X^TX$ é semidefinida positiva.

c. Monte X^TX e X^Ty explicitamente para $p = 1$ e recupere o Exercício 3.5.

Solução:

a. $\frac{\partial}{\partial x_k}(v^Tx) = v_k \implies \frac{\partial(v^Tx)}{\partial x} = v$. $\frac{\partial}{\partial x_k}(x^TAx) = \sum_j A_{kj}x_j + \sum_i A_{ik}x_i = 2(Ax)_k \implies \frac{\partial(x^TAx)}{\partial x} = 2Ax$.

b. $\text{RSS}(\beta) = y^Ty - 2\beta^TX^Ty + \beta^TX^TX\beta$.

$$\frac{\partial \text{RSS}}{\partial \beta} = -2X^Ty + 2X^TX\beta = 0 \implies X^TX\beta = X^Ty$$

A Hessiana $\nabla^2\text{RSS} = 2X^TX$ satisfaz $v^T(2X^TX)v = 2\|Xv\|^2 \geq 0$, sendo semidefinida positiva.

c. Para $p = 1$, $X = [\mathbf{1}\ x]$.

$$X^TX = \begin{bmatrix} N & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix}, \quad X^Ty = \begin{bmatrix} \sum y_i \\ \sum x_iy_i \end{bmatrix}$$

O sistema $X^TX\hat{\beta} = X^Ty$ recupere exatamente as equações normais do Exercício 3.5.

Exercício 3.12 [Demonstração — A Matriz Chapéu H]

Enunciado: Seja $H = X(X^TX)^{-1}X^T$.

a. Mostre que H é simétrica e idempotente ($H^2 = H$), $HX = X$ e $(I - H)X = 0$.

b. Mostre que $r \perp \text{col}(X)$. O que $r \perp \mathbf{1}$ diz sobre os resíduos?

c. Para todo β, mostre $\|y - X\beta\|^2 = \|y - \hat{y}\|^2 + \|\hat{y} - X\beta\|^2$.

d. Mostre que $\hat{y}$ é único mesmo se colunas de X forem L.D.

e. Mostre $\text{tr}(H) = p + 1$ e interprete o peso médio $(p + 1)/N$.

f. (Desafio) Mostre $0 \leq h_{ii} \leq 1$ e interprete $h_{ii} = 1$.

Solução:

a. $H^T = X(X^TX)^{-1}X^T = H$. $H^2 = X(X^TX)^{-1}X^TX(X^TX)^{-1}X^T = H$. $HX = X(X^TX)^{-1}X^TX = X$. $(I - H)X = X - X = 0$.

b. $X^Tr = X^T(I - H)y = 0$. Logo $r \perp \text{col}(X)$. Se a 1ª coluna for $\mathbf{1}$, $\mathbf{1}^Tr = 0 \implies \sum r_i = 0$.

c. $\|y - X\beta\|^2 = \|r + X(\hat{\beta} - \beta)\|^2 = \|r\|^2 + \|X(\hat{\beta} - \beta)\|^2 + 2(\hat{\beta} - \beta)^TX^Tr$. Como $X^Tr = 0$, o termo cruzado anula-se, provando a decomposição de Pitágoras.

d. A projeção ortogonal de y sobre um subespaço vetorial $\text{col}(X)$ é geometricamente única.

e. $\text{tr}(H) = \text{tr}(X(X^TX)^{-1}X^T) = \text{tr}((X^TX)^{-1}X^TX) = \text{tr}(I_{p+1}) = p + 1$. A média da diagonal é $(p + 1)/N$.

f. Como $H = H^2$, $h_{ii} = \sum_j h_{ij}^2 = h_{ii}^2 + \sum_{j \neq i} h_{ij}^2 \geq h_{ii}^2 \implies 0 \leq h_{ii} \leq 1$. Se $h_{ii} = 1$, $h_{ij} = 0$ $(\forall j \neq i)$, logo $\hat{y}_i = y_i$ e $r_i = 0$ (ponto de alavancagem máxima).

Exercício 3.13 [Demonstração — Modelos Aninhados e RSS]

Enunciado: Seja X_1 $(N \times (q + 1))$ e $X_2 = [X_1\ Z]$.

a. Mostre que $\text{RSS}_2 \leq \text{RSS}_1$ em uma linha.

b. Prove geometricamente por subespaços.

c. Mostre $\hat{y}_2 = \hat{y}_1 + H_2r_1$ e $\text{RSS}_1 - \text{RSS}_2 = \|H_2r_1\|^2$.

d. Conclua que R^2 de treino nunca diminui. Por que ele não serve para escolher modelos?

e. O resultado vale para a RSS de teste?

Solução:

a. $\text{RSS}_2 = \min_{\beta,\gamma} \|y - X_1\beta - Z\gamma\|^2 \leq \min_{\beta} \|y - X_1\beta - \mathbf{0}\|^2 = \text{RSS}_1$.

b. $\text{col}(X_1) \subseteq \text{col}(X_2)$. A distância ao subespaço maior $\text{col}(X_2)$ é menor ou igual.

c. $H_2y = H_2(\hat{y}_1 + r_1) = \hat{y}_1 + H_2r_1 \implies \hat{y}_2 = \hat{y}_1 + H_2r_1$. Por Pitágoras: $\|r_1\|^2 = \|H_2r_1\|^2 + \|r_2\|^2 \implies \text{RSS}_1 - \text{RSS}_2 = \|H_2r_1\|^2$. Igualdade ocorre $\iff Z^Tr_1 = 0$.

d. Como $R^2 = 1 - \frac{\text{RSS}}{\text{TSS}}$, R^2 é não-decrescente. Ele favorece sobreajuste e modelos desnecessariamente complexos.

e. Não vale para o teste! Preditores irrelevantes aumentam a variância do modelo, elevando a RSS de teste.

Exercício 3.14 [Demonstração Desafio — Estimador de Menor Variância (Gauss-Markov)]

Enunciado: Suponha $y = X\beta + \varepsilon$ com $E[\varepsilon] = 0$ e $\text{Var}(\varepsilon) = \sigma^2 I$.

a. Mostre $E[\hat{\beta}] = \beta$ e $\text{Var}(\hat{\beta}) = \sigma^2(X^TX)^{-1}$.

b. Seja $\tilde{\beta} = Cy$ não-viesado. Mostre $CX = I$.

c. Mostre $\text{Var}(\tilde{\beta}) = \text{Var}(\hat{\beta}) + \sigma^2 DD^T$ para $C = (X^TX)^{-1}X^T + D$.

d. Ridge tem variância menor. Contradiz Gauss-Markov?

Solução:

a. $E[\hat{\beta}] = (X^TX)^{-1}X^T(X\beta) = \beta$. $\text{Var}(\hat{\beta}) = (X^TX)^{-1}X^T(\sigma^2 I)X(X^TX)^{-1} = \sigma^2(X^TX)^{-1}$.

b. $E[Cy] = CX\beta = \beta\ (\forall\beta) \implies CX = I$.

c. $C = (X^TX)^{-1}X^T + D \implies CX = I + DX = I \implies DX = 0$.

$$\text{Var}(\tilde{\beta}) = \sigma^2 CC^T = \sigma^2\left((X^TX)^{-1}X^T + D\right)\left(X(X^TX)^{-1} + D^T\right) = \sigma^2(X^TX)^{-1} + \sigma^2 DD^T$$

Como DD^T é semidefinida positiva, MQO possui variância mínima entre estimadores lineares não-viesados.

d. Não contradiz! O estimador ridge é **viesado**, enquanto o Teorema de Gauss-Markov restringe-se a estimadores **não-viesados**.

Exercício 3.15 [Demonstração Desafio — Otimismo do Erro de Treino]

Enunciado:

a. Mostre $r = (I - H)\varepsilon$.

b. Mostre $E[\text{RSS}] = \sigma^2(N - p - 1)$ e que $\hat{\sigma}^2 = \frac{\text{RSS}}{N-p-1}$ é não-viesado.

c. Para novas respostas y^*, mostre $\frac{1}{N}E[\|y^* - \hat{y}\|^2] = \sigma^2\left(1 + \frac{p+1}{N}\right)$.

d. Conclua que o otimismo é $\frac{2\sigma^2(p+1)}{N}$.

Solução:

a. $r = (I - H)y = (I - H)(X\beta + \varepsilon) = (I - H)\varepsilon$, pois $(I - H)X = 0$.

b. $E[\text{RSS}] = E[\varepsilon^T(I - H)\varepsilon] = \sigma^2\text{tr}(I - H) = \sigma^2(N - p - 1) \implies E[\hat{\sigma}^2] = \sigma^2$.

c. $y^* - \hat{y} = \varepsilon^* - H\varepsilon \implies E[\|y^* - \hat{y}\|^2] = E[\|\varepsilon^*\|^2] + E[\varepsilon^T H\varepsilon] = N\sigma^2 + (p+1)\sigma^2$.

d. Otimismo $= E[\text{MSE}_{\text{teste}}] - E[\text{MSE}_{\text{treino}}] = \sigma^2\left(1 + \frac{p+1}{N}\right) - \sigma^2\left(1 - \frac{p+1}{N}\right) = \frac{2\sigma^2(p+1)}{N}$.

Exercício 3.16 [Demonstração Desafio — LOOCV em Tempo Constante]

Enunciado:

a. Mostre que substituir y_i por $\hat{y}_i^{(-i)}$ resulta no ajuste $\hat{\beta}^{(-i)}$.

b. Mostre que $y_i - \hat{y}_i^{(-i)} = \frac{r_i}{1-h_{ii}}$.

c. Conclua a fórmula do LOOCV: $\mathrm{CV}_{(N)} = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{r_i}{1-h_{ii}}\right)^2$.

d. Interprete o efeito de pontos com $h_{ii} \to 1$.

Solução:

a. O vetor y^c modificado satisfaz $(X^TX - x_i x_i^T)\hat{\beta}^{(-i)} = \sum_{j\neq i} x_j y_j$. Logo $\hat{\beta}^c = \hat{\beta}^{(-i)}$.

b. $\hat{y}_i^{(-i)} = \sum_{j\neq i} h_{ij}y_j + h_{ii}\hat{y}_i^{(-i)} \implies \hat{y}_i^{(-i)}(1-h_{ii}) = \hat{y}_i - h_{ii}y_i \implies y_i - \hat{y}_i^{(-i)} = \frac{y_i - \hat{y}_i}{1-h_{ii}} = \frac{r_i}{1-h_{ii}}$.

c. $\mathrm{CV}_{(N)} = \frac{1}{N}\sum(y_i - \hat{y}_i^{(-i)})^2 = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{r_i}{1-h_{ii}}\right)^2$.

d. Pontos de alta alavancagem ($h_{ii} \approx 1$) possuem denominador próximo de zero, penalizando fortemente o erro de validação.

3 Acurácia dos Coeficientes

Exercício 3.17 [Demonstração Desafio — Teorema de Frisch-Waugh-Love]

Enunciado: Seja $X = [X_1\ x_2]$, $\tilde{x}_2 = (I - H_1)x_2$ e $\tilde{y} = (I - H_1)y$.

a. Mostre $\hat{\beta}_2 = \frac{\tilde{x}_2^T \tilde{y}}{\tilde{x}_2^T \tilde{x}_2}$.

b. Interprete o efeito de x_2 controlando os outros preditores e a mudança de sinal.

c. Quando o coeficiente múltiplo coincide com o simples?

d. Mostre $\text{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\|\tilde{x}_2\|^2}$ e comente sobre colinearidade.

Solução:

a. Pelo Teorema FWL, a regressão de y projeta sobre a componente ortogonal de x_2 em relação a X_1:

$$\hat{\beta}_2 = \frac{\tilde{x}_2^T \tilde{y}}{\tilde{x}_2^T \tilde{x}_2} = \frac{\tilde{x}_2^T y}{\|\tilde{x}_2\|^2}$$

b. $\hat{\beta}_2$ mede a relação isolada de x_2 após remover todo efeito explicado por X_1. Se x_2 for correlacionado com preditores omitidos, a regressão simples atribui a x_2 efeitos de confundimento, alterando o sinal em relação à regressão múltipla.

c. Coincidem quando $\tilde{x}_2 = x_2 \iff X_1^T x_2 = 0$ (ortogonalidade perfeita).

d. $\text{Var}(\hat{\beta}_2) = \frac{\tilde{x}_2^T (\sigma^2 I) \tilde{x}_2}{\|\tilde{x}_2\|^4} = \frac{\sigma^2}{\|\tilde{x}_2\|^2}$. Se x_2 for colinear a X_1, $\|\tilde{x}_2\| \to 0$, fazendo a variância inflar ($\text{Var}(\hat{\beta}_2) \to \infty$).

Exercício 3.18 [Programação — Implementando o Caso Geral]

Enunciado: Implemente `ols(X, y)` com NumPy adicionando a coluna de uns e resolvendo equações normais com `np.linalg.solve`. Valide contra `ols_p1`. Duplique uma coluna de X e relate o resultado.

Comentário Teórico: *[Questão Computacional — apenas enunciado e comentário teórico]* Este exercício requer a construção da função matricial $\hat{\beta} = (X^T X)^{-1} X^T y$ através da resolução de sistemas lineares $X^T X \hat{\beta} = X^T y$ via decomposição numérica (`np.linalg.solve`), evitando a inversão explícita. Ao duplicar uma coluna da matriz de design X, introduz-se multicolinearidade perfeita ($\text{posto}(X) < p + 1$), tornando $X^T X$ singular e sem inversa definida, o que faz o resolvedor numérico disparar um erro de matriz singular (`LinAlgError`).

Exercício 3.19 [Conceitual — O que o Erro-Padrão Mede?]

Enunciado:

a. No modelo $Y = \beta_0 + \beta_1 X + \varepsilon$, quais objetos são fixos e quais são aleatórios?

b. Onde $\text{SE}(\hat{\beta}_1)$ é visualizado no Exercício 3.4?

c. A fórmula usa σ^2. Pelo que se troca e por que a troca é honesta?

d. Como $\text{SE}(\hat{\beta}_1)$ varia com: dobrar N; pH mais variado; laboratório mais preciso; trocar unidades?

e. É possível reduzir $\text{SE}(\hat{\beta}_1)$ coletando mais variáveis?

f. $\text{SE}(\hat{\beta}_1)$ pequeno garante boa previsão?

Solução:

a. Fixos: β_1, x_i. Aleatórios: $\varepsilon_i, y_i, \hat{\beta}_1$. Refere-se à amostragem repetida com x_i fixos e novos ruídos.

b. É o desvio padrão do histograma das estimativas $\hat{\beta}_1$ obtidas nas simulações do Ex. 3.4.

c. Troca-se σ^2 por $\hat{\sigma}^2 = \frac{\text{RSS}}{N-p-1}$. É honesto pois $E[\hat{\sigma}^2] = \sigma^2$.

d. (1) Dobrar N: cai por $\sqrt{2}$. (2) pH mais variado: diminui. (3) Lab preciso: diminui. (4) Trocar unidades: altera na mesma proporção de escala.

e. Se as novas variáveis reduzirem σ^2 sem colinearidade, sim; se forem colineares com x_1, a variância de $\hat{\beta}_1$ aumenta.

f. Não! $\text{SE}(\hat{\beta}_1)$ mede incerteza sobre o parâmetro médio, não sobre instâncias individuais (que dependem de σ^2).

Exercício 3.20 [Conceitual]

Enunciado: Arsênio ($N = 660$), $\hat{\beta}_{\text{pH}} = 15.2$ (IC 95% $[10.3, 20.1]$) e $\hat{\beta}_{\text{turb}} = -2.1$ (IC 95% $[-5.2, 1.0]$).

a. O que é aleatório na frase do IC 95%?

b. Critique interpretações equivocadas.

c. Interprete os intervalos ambientalmente.

d. Se $N \to 2640$, quanto encolhe o intervalo?

e. De onde vem $\hat{\beta} \pm 2\text{SE}$? O que muda com $N = 8$?

f. Ordene as meias-larguras dos ICs de β_1, $f(x_0)$ e Y_0.

Solução:

a. O parâmetro β é fixo; o **intervalo é o objeto aleatório** que varia a cada amostragem.

b. "Há 95% de chance de β estar no IC" está errado (frequentista); "95% das estações têm efeito no intervalo" confunde média com variação individual.

c. pH: aumento significativo de 10.3 a 20.1 μg/L por unidade de pH. Turbidez: intervalo contém zero, sem efeito conclusivo.

d. Como N quadruplicou, a largura encolhe pela metade ($\sqrt{4} = 2$).

e. Vem do quantil $z_{0.975} \approx 1.96 \approx 2$. Para $N = 8$, usa-se $t_{6,0.975} \approx 2.447$ (intervalo mais largo).

f. Largura: $\text{IC}(\beta_1) \leq \text{IC}(f(x_0)) < \text{IP}(Y_0)$. O de previsão (IP) é o maior pois contém o erro irredutível σ^2.

Exercício 3.21 [Conceitual]

Enunciado:

a. Escreva H_0, H_1 para a turbidez. Por que testar ausência de efeito?

b. O que $t = \hat{\beta}_j/\text{SE}$ compara?

c. Defina valor-p e critique erros comuns.

d. Condutividade: $\hat{\beta} = 0.0007, p < 0.001$. É relevante?

e. Trocar unidades altera t e valor-p?

f. Em 20 preditores nulos a 5%, quantos "significativos" espera-se encontrar?

g. $Y = X^2 + \varepsilon$ simétrico deu $p = 0.8$. O teste errou?

Solução:

a. $H_0 : \beta_{\text{turb}} = 0$ vs $H_1 : \beta_{\text{turb}} \neq 0$. Testa-se H_0 por ser uma hipótese pontual bem definida para falsificação.

b. Compara o sinal ($\hat{\beta}_j$) com o ruído de estimação (SE).

c. Valor-p: probabilidade de obter estatística tão ou mais extrema sob H_0. Erros: não é a prob de H_0 ser verdadeira nem prob do acaso.

d. É estatisticamente significativo, mas a relevância prática depende da variação da condutividade na escala real.

e. Não altera! $\hat{\beta}$ e SE são multiplicados pela mesma constante c, mantendo t e o p-valor invariantes.

f. Espera-se $20 \times 0.05 = 1$ falso positivo por acaso. A estatística F resolve essa inflação de tipo I.

g. Não errou! O teste avalia a associação **linear**. Como $\text{Cov}(X, X^2) = 0$ para X simétrico, a componente linear é nula.

Exercício 3.22 [Prático — Tabela de Regressão]

Enunciado: Tabela de regressão para arsênio ($N = 660$):

Coeficiente	$\hat{\beta}$	**SE**	t	**Valor-p**
Intercepto	-12.0	3.1	?	< 0.001
pH	15.2	2.5	?	< 0.001
Turbidez (NTU)	-2.1	1.6	?	0.19
Condutividade (μS/cm)	0.030	0.004	?	< 0.001

a. Complete a coluna t.

b. Construa ICs de 95%.

c. Escreva conclusões para o órgão ambiental.

d. Preveja o arsênio para pH=7, Turb=20, Cond=300.

e. Reescreva condutividade em mS/cm.

f. Avalie a remoção da turbidez do modelo.

Solução:

a. $t = \hat{\beta}/\text{SE}$: Intercepto $t = -3.87$; pH $t = 6.08$; Turbidez $t = -1.31$; Condutividade $t = 7.50$.

b. IC 95% ($\hat{\beta} \pm 1.96\text{SE}$): Intercepto $[-18.08, -5.92]$; pH $[10.30, 20.10]$; Turbidez $[-5.24, 1.04]$ (contém zero); Condutividade $[0.022, 0.038]$.

c. pH e condutividade apresentam efeitos positivos estatisticamente significativos. A turbidez não apresenta efeito conclusivo a 5%.

d. $\hat{y} = -12.0 + 15.2(7) - 2.1(20) + 0.030(300) = 61.4$ μg/L. O erro de uma nova medição é maior devido a σ^2.

e. Em mS/cm: $\hat{\beta} = 30.0$, SE $= 4.0$. $t = 7.50$ e $p < 0.001$ permanecem idênticos.

f. Remover a turbidez assume que ela é ortogonal aos demais preditores. Se for correlacionada, os outros coeficientes mudarão.

Exercício 3.23 [Demonstração Desafio]

Enunciado:

a. Justifique $\text{SE}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{\sum(x_i - \bar{x})^2}}$ com $\hat{\sigma}^2 = \frac{\text{RSS}}{N-2}$.

b. Mostre a invariância de t a mudanças de escala.

c. Mostre $t^2 = F$ para $p = 1$.

d. Mostre $t^2 = \frac{(N-2)R^2}{1-R^2}$ e comente $N \to \infty$.

e. (Desafio) Mostre a transição de gaussiana para t de Student.

Solução:

a. $\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum(x_i - \bar{x})^2}$. Usa-se $N - 2$ pois 2 graus de liberdade foram estimados (β_0, β_1).

b. Se $x' = c_x x, y' = c_y y \implies \hat{\beta}_1' = \frac{c_y}{c_x}\hat{\beta}_1$ e $\text{SE}' = \frac{c_y}{c_x}\text{SE} \implies t' = t$.

c. $F = \frac{\text{ESS}/1}{\text{RSS}/(N-2)} = \frac{\hat{\beta}_1^2 \sum(x_i - \bar{x})^2}{\hat{\sigma}^2} = \left(\frac{\hat{\beta}_1}{\text{SE}(\hat{\beta}_1)}\right)^2 = t^2$.

d. $t^2 = (N-2)\frac{\text{ESS}}{\text{RSS}} = (N-2)\frac{R^2}{1-R^2}$. Para $N \to \infty$, qualquer $R^2 > 0$ torna-se significativo.

e. Substituir σ por $\hat{\sigma} = \sqrt{\frac{\text{RSS}}{N-2}}$, onde $\frac{\text{RSS}}{\sigma^2} \sim \chi^2_{N-2}$, transforma a normal padrão na distribuição t de Student com $N - 2$ graus de liberdade.